

1 线性规划

1.1 线性规划问题

线性规划问题三要素：

- 决策变量：决策变量是问题中要确定的未知量，决策者通过调控决策变量来选取不同的方案、设计、措施以达到最优目的。
- 目标函数：目标函数通常是决策变量的函数，表达了“何为最优”的准则和目标，规定了优化问题的实际意义。
- 约束条件：约束条件指决策变量取值时受到的各种资源和条件的限制，表达了一种“有条件优化”的概念，通常为决策变量的等式或不等式方程。

如果决策变量的取值是连续的，且目标函数和约束条件都是决策变量的线性函数，称为线性规划问题。

如果决策点取值点为整数，称为整数规划问题。

如果果部分决策变量取值连续而其余取值为整数，称为混合整数规划问题。

如果目标函数和约束条件中存在任何的非线性因子，称为非线性规划问题。

例题：

例2.1 生产计划的安排问题

设某企业现有 m 种物资资源 $B_i(i = 1, 2, \dots, m)$ 用于生产 n 种产品 A_j ($j=1, 2, \dots, n$)，每种资源的拥有量和每种单位产品所消耗的资源量，以及单位产品的利润如表2-1所示，试问如何安排生产计划使得企业获利最大？

表 2-1 资源的拥有量和单位产品的利润。

产品 \ 资源	A_1	A_2	$\dots$	A_n	总量
B_1	a_{11}	a_{12}	$\dots$	a_{1n}	b_1
B_2	a_{21}	a_{22}	$\dots$	a_{2n}	b_2
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
B_m	a_{m1}	a_{m2}	$\dots$	a_{mn}	b_m
利润	c_1	c_2	$\dots$	c_n	

设产品 A_j 的产量为 $x_j(j=1, 2, \dots, n)$ ，称之为决策变量；

所得的利润为 z ；

则要解决问题的目标是使得（利润）函数 $z = \sum_{j=1}^n c_j x_j$ 有最大值；

决策变量所受的约束条件为

$$\begin{cases} \sum_{j=1}^n a_{ij} x_j \leq b_i & (i = 1, 2, \dots, m), \\ x_j \geq 0 & (j = 1, 2, \dots, n). \end{cases}$$

线性规划问题的图解法求解

线性规划问题的求解方法：

- 低维线性规划（如两个决策变量）问题的图解求法
- 高位线性规划（三个决策变量以上）问题单纯型求解法

满足约束条件的决策变量向量在n维空间中构成的点的集合称为解的**可行域**，而可行域中使目标函数达到最优的解点称为**最优解**，相应于最优解的目标函数值称为**最优值**

对线性规划问题来说，如果**仅含有两个决策变量**，则其可行域可以在平面上画出，最优解可由**图解法**确定。

- 以两个决策变量为轴在平面上建立直角坐标系；
- 图示由线性等式和不等式构成的约束条件，标出可行域；
- 图示并移动目标函数，寻找最优解。

例：用图解法解

$$\begin{aligned} \min & \{-x_1 - 4x_2\} \\ \text{s.t. } & x_1 + x_2 \leq 4 \\ & -x_1 + x_2 \leq 2 \\ & x_1, x_2 \geq 0 \end{aligned}$$





图 2-1 图解法求解线性规划

但是一般情况下未必能找到最优解，有三种情况：

- (1) 无穷多最优解（多重解）

上例中若取 $\min z=3x_1+3x_2$ ，则目标函数线与 $x_1+x_2=4$ 边界线重合，带来无穷多解。



(2) 无界解

(2) 无界解


例如下述线性规划问题：

$$\text{Max } z=x_1+x_2$$

$$-2x_1+x_2 \leq 4$$

$$x_1-x_2 \leq 2$$

$$x_1, x_2 \geq 0$$



但是， $\max z$ 虽无界， $\min z$ 却有唯一解 $(0,0)$

(3) 无可行解，无解

若可行域为空，则无可行解，自然无最优解。

1.2 线性规划问题的数学模型

线性规划问题一般形式

$$\begin{aligned} \max(\min) z &= \sum_{j=1}^n c_j x_j \\ \text{s. t. } \begin{cases} \sum_{j=1}^n a_{ij} x_j \leq (\geq, =) b_i & (i = 1, 2, \dots, m), \\ x_j \geq 0 & (j = 1, 2, \dots, n). \end{cases} \end{aligned}$$

也可表示为矩阵形式

$$\max(\min) z = c \cdot x$$

$$\text{s.t.} \begin{cases} Ax \leq (\geq, =) b \\ x \geq 0. \end{cases}$$

或者向量形式

$$\max(\min) z = c \cdot x$$

$$\text{s.t.} \begin{cases} \sum_{j=1}^n p_j x_j \leq (\geq, =) b \\ x \geq 0. \end{cases}$$

其中 $c = (c_1, c_2, \dots, c_n)$ 为目标函数的系数向量

$x = (x_1, x_2, \dots, x_n)^T$ 为决策向量

$b = (b_1, b_2, \dots, b_n)$ 为常数向量

$A = (a_{ij})_{m \times n}$ 为约束方程组的系数矩阵

$p_j = (a_{1j}, a_{2j}, \dots, a_{mj})^T$ 为约束方程组的系数向量

由上面可以看出，线性规划的目标函数可以是最大值，也可以是最小值；约束条件有的是 $\leq$ ，有 $\geq$ ，也可以是 $=$ ；决策变量可以是非负的，也可以非正的，甚至可以无约束；

为了便于研究，规定标准型为

$$\max z = c \cdot x$$

$$\text{s.t.} \begin{cases} Ax = b \\ x \geq 0. \end{cases}$$

对于非标准型都可以转化为标准型：

- 目标函数是最小化 $\min z$ 时，令 $z' = -z$ ： $\min z$ 转化为 $\max z'$
- 约束条件不等式：对于不等号的约束条件，在 $\leq$ 的左端或者 $\geq$ 的右端加上或减去一个非负变量（松弛变量）使其变为等式。
- 对于非正的决策变量，取负即可；对于无约束的决策变量如 $x \in (-\infty, \infty)$ ，可以令 $x = x' - x''$ ，其中 $x', x'' \geq 0$ ，即将一个无约束的转化为两个恒大于0的表示，也确实能表示两端无穷的范围。

例：

$$\text{Min } z = -x_1 + 2x_2 - 3x_3$$

$$x_1 + x_2 + x_3 \leq 7$$

$$x_1 - x_2 + x_3 \geq 2$$

$$-3x_1 + x_2 + 2x_3 = 5$$

$$x_1, x_2 \geq 0$$

化为标准形式。

解：(1) 因 x_3 无约束，令 $x_3 = x_4 - x_5$ ， $x_4, x_5 \geq 0$

(2) $x_1 + x_2 + x_3 \leq 7 \rightarrow x_1 + x_2 + (x_4 - x_5) + x_6 = 7$; 等式左端加入松弛因子 x_6

(3) $x_1 - x_2 + x_3 \geq 2 \rightarrow x_1 - x_2 + (x_4 - x_5) = 2 + x_7$; 等式右端加入松弛因子

(4) $-3x_1 + x_2 + 2x_3 = 5 \rightarrow -3x_1 + x_2 + 2(x_4 - x_5) = 5$

其中： $x_1, x_2, x_4, x_5, x_6, x_7 \geq 0$

对目标函数， $\min z = -x_1 + 2x_2 - 3x_3$ 转化为
 $\max z' = -(-x_1 + 2x_2 - 3(x_4 - x_5) + 0x_6 + 0x_7)$

这样就转化为了标准型

1.3 线性规划解的基本概念与基本理论

对于标准型

$$\max \quad z = C \cdot X \quad (2.5)$$

$$s.t. \quad \begin{cases} AX = b \\ X \geq 0 \end{cases} \quad (2.6)^+$$

(1) 满足约束条件的解 $x = (x_1, \dots, x_n)^T$ 为线性规划问题的可行解；所有可行解的集合是可行域，记为 D ；使得目标函数达到最大的可行解是最优解。

(2) 设系数矩阵 $A = (a_{ij})_{m \times n}$ 的秩为 m ，则称 A 的某个 $m \times m$ 非奇异子矩阵 B 为线性规划问题的一个基，设 $B = (a_{ij})_{m \times m} = (p_1, \dots, p_m)$ ，称 $p_j = (a_{1j}, a_{2j}, \dots, a_{mj})^T$ 为基向量，矩阵 A 的其他列向量为非基向量，与基向量对应的决策变量 x_j 为基变量，其他的变量为非基变量。

(3) 基解 设问题的基为 B ，可以将约束方程组变为

$$\sum_{j=1}^m p_j x_j = b - \sum_{j=m+1}^n p_j x_j$$

在他的解中令 $x_j = 0 (j = m + 1, \dots, n)$ ，则称解向量 $x = (x_1, x_2, \dots, x_m, 0, \dots, 0)^T$ 为问题的基解

(4) 满足非负约束条件的基解称为基可行解

(5) 对应于基可行解的基称为可行基

假设 K 为 n 维欧氏空间 E^n 中点集，如果对于任意两点 $x^{(1)}, x^{(2)} \in K$ ，其连线上一切点 $x = \lambda x^{(1)} + (1 - \lambda)x^{(2)} \in K (0 \leq \lambda \leq 1)$ 则称 K 为凸集。实心圆、实心球是凸集；空心圆，空心球不是凸集，凸集没有凹入部分。

设 $x^{(1)}, x^{(2)}, \dots, x^{(k)}$ 是 n 维欧氏空间 E^n 中的 k 个点. 如果存在

$\lambda_i: 0 \leq \lambda_i \leq 1 (i = 1, 2, \dots, k), \text{ 且 } \sum_{i=1}^k \lambda_i = 1$, 使得

$$x = \lambda_1 x^{(1)} + \lambda_2 x^{(2)} + \dots + \lambda_k x^{(k)}$$

则称 x 为 $x^{(1)}, x^{(2)}, \dots, x^{(k)}$ 的凸组合。

对于凸集 K 中的点 x , 如果 x 不能用相异的两点 $x^{(1)}, x^{(2)} \in K$ 的凸组合表示为

$x = \lambda x^{(1)} + (1 - \lambda)x^{(2)} \in K (0 \leq \lambda \leq 1)$, 则称 x 为凸集 K 的一个顶点(或极点) (对于凸集, 顶点一般为边界点, 但是并非所有边界点都是顶点)

解决线性规划问题的几个基本理论

定理一: 如果线性问题的约束条件存在可行域 D , 则其可行域 $D = \{x | \sum_{j=1}^n p_j x_j = b, x_j \geq 0\}$ 一定为凸集

定理二: 任何一个基可行解 x 必对应于可行域 D 的一个顶点($m+1, \dots, n$ 为0的解)

定理三: 若线性规划问题可行域有界, 则问题的最优解一定在可行域的顶点上达到; 若可行域无界, 则问题可能无最优解, 有最优解也在可行域某个顶点上达到。

总结:

- 所有可行解构成的集合是凸集, 也可能是无界域;
- 线性规划的可行域有有限个顶点;
- 线性规划每个基可行解对应一个顶点;
- 若线性规划有最优解, 必定在某个顶点上达到, 但是并非只能在顶点上达到。

1.4 线性规划求解的单纯形法

由于最优解在顶点上达到, 而线性规划的每个基可行解对应可行域的一个顶点

因此求解思路为: 求基可行解, 检查其是否为最优解, 如果不是再求另一个基可行解, 再检查, 知道找到最优解

1.4.1 初始基可行解的确定

单纯形法的基础是线性规划标准型(约束方程为全等式)

如果线性规划不是标准型化为标准型

如果是标准型, 从系数矩阵 $A = (a_{ij})_{m \times n}$ (秩为 m) 总可以得到一个 m 阶单位阵 E_m , 例如可以通过高斯消元法对 A 进行初等变换, 得到一个 m 阶单位阵 E_m

取上 m 阶单位阵 E_m 为初始可行基, 即 $B=E_m$, 将相应的约束方程组变为

$$x_i = b_i - a_{i,m+1}x_{m+1} - \dots - a_{i,n}x_n (i = 1, 2, \dots, m)$$

令方程组后面 $n-m$ 个变量为0, 得到一个初始基可行解。

$$x^{(0)} = (x_1^{(0)}, x_2^{(0)}, \dots, x_m^{(0)}, 0, \dots, 0)^T = (b_1, b_2, \dots, b_m, 0, \dots, 0)^T$$

(这不是, 解线性方程组的某个方法吗)

1.4.2 寻找另一个基可行解

当一个基可行解不是最优解或者不能判断时，需要过渡到另一个基可行解，即从原来的 $x_1 \sim x_m$ 对应的可行基 B 中替换一个列向量，用来替换的列向量与原向量组其他向量线性无关。假设用非基向量 p_{m+t} （换入向量）替换基变量 p_l （换出变量），得到一个新的可行基 B^1 ，从而可以求出一个新的基可行解，此方法称为基变换法。

事实上，这个新的基可行解可以用以下公式直接计算出来：

$$x_i^{(1)} = \begin{cases} x_i^{(0)} - \theta \beta_{i,m+t}, & i \neq l \\ \theta, & i = l \end{cases} \quad \begin{cases} i = 1, 2, \dots, m, \\ 1 \leq l \leq m, 1 \leq t \leq n - m \end{cases}$$

$$\text{其中 } \theta = \frac{x_l^{(0)}}{\beta_{l,m+t}} = \min_{1 \leq i \leq m} \left\{ \frac{x_i^{(0)}}{\beta_{i,m+t}} \mid \beta_{i,m+t} > 0 \right\}, \quad p_{m+t} = \sum_{i=1}^m \beta_{i,m+t} p_i$$

如果 $x^{(1)} = (x_1^{(1)}, x_2^{(1)}, \dots, x_m^{(1)}, 0, \dots, 0)^T$ 仍不是最优解，则可以重复利用这种方法，直到得到最优解为止。

1.4.3 最优性检验方法

假设要检验基可行解

$$x^{(1)} = (x_1^{(1)}, x_2^{(1)}, \dots, x_m^{(1)}, 0, \dots, 0)^T = (b'_1, b'_2, \dots, b'_m, 0, \dots, 0)^T$$

的最优性，由约束方程 $Ax=b$ ，要再任取一个 x ，对这个 x ，有如下取法。

$$x_i = b'_i - \sum_{j=m+1}^n a'_{ij} x_j \quad (i = 1, 2, \dots, m)$$

将基可行解与这个任意 x 分别代入目标函数

$$\begin{aligned} z^{(1)} &= \sum_{i=1}^m c_i x_i^{(1)} = \sum_{i=1}^m c_i b'_i \\ z &= \sum_{i=1}^n c_i x_i = \sum_{i=1}^m c_i x_i + \sum_{j=m+1}^n c_j x_j \\ &= \sum_{i=1}^m c_i \left(b'_i - \sum_{j=m+1}^n a'_{ij} x_j \right) + \sum_{j=m+1}^n c_j x_j \\ &= \sum_{i=1}^m c_i b'_i + \sum_{j=m+1}^n \left(c_j - \sum_{i=1}^m c_i a'_{ij} \right) x_j \\ &= z^{(1)} + \sum_{j=m+1}^n (c_j - z_j) x_j \end{aligned}$$

$$\text{其中 } z_j = \sum_{i=1}^m c_i a'_{ij} \quad (j = m+1, \dots, n). \text{ 记 } \sigma_j = c_j - z_j \quad (j = m+1, \dots, n), \text{ 则}$$

$$z = z^{(1)} + \sum_{j=m+1}^n \sigma_j x_j$$

z_j 的意义为，第 j 个决策变量 x_j 的系数 c_j 乘上在系数矩阵中其对应的该列的系数的和的乘积。

可见 $\sigma_j > 0$ 时 $z > z^{(1)}$; $\sigma_j \leq 0$ 时 $z \leq z^{(1)}$; 为此, 他的符号是判别 $x^{(1)}$ 是否为最优解的关键所在, 故称之为检验数, 于是有

- 如果 $\sigma_j \leq 0$, 则 $x^{(1)}$ 是问题的最优解, 最优值是 $z^{(1)}$
- 如果 $\sigma_j \leq 0$ 且至少存在一个 $\sigma_{m+k} = 0 (0 \leq k \leq n - m)$, 则问题有无穷多最优解, $x^{(1)}$ 是其中之一, 最优值是 $z^{(1)}$
- 如果 $\sigma_j < 0$, 则 $x^{(1)}$ 是问题的**唯一**最优解, 最优值是 $z^{(1)}$
- 如果存在某个检验数 $\sigma_{m+k} > 0 (0 \leq k \leq n - m)$, 并且对应的系数向量 p_{m+k} 的各分量 $a_{i,m+k} \leq 0 (i = 1, \dots, m)$, 则问题有无界解。

这些东西人工求解太抽象了, 目前都用软件求解 (matlab)

1.2.5 灵敏度分析

在线性规划模型

$$\begin{aligned} \max z &= c \cdot x \\ \text{s.t.} \begin{cases} Ax = b \\ x \geq 0. \end{cases} \end{aligned}$$

中, **总假设A, b, c都是常数。**

但这些数值在许多情况都是由试验或测量得到的, 特别是在迭代计算中也都是近似值。一般A表示工艺条件, b表示资源条件, c表示市场条件, **实际中可能有多种原因引起它们的变化。**

现在的问题是: 这些系数在什么范围内变化时, 线性规划问题最优解不变?

这就是灵敏度分析要研究的问题。

2 整数规划

如果一个数学规划的某些决策变量或全部决策变量要求必须取整数, 则 这样的问题称为整数规划问题; 相应的模型称为整数规划模型。在整数规划中, 如果所有的决策变量都为非负整数, 则称之为纯整数规划问题; 否则称之为混合整数规划问题。有时, 要求决策变量为只能取0或1的逻辑变量, 则称为0 - 1规划。

2.1 一般整数规划的求解方法—分枝定界法

整数规划解朴素解法有穷举法和线性规划解再四舍五入, 实际上都不合理

分枝定界法:

- 步1: 设有最大化的整数规划问题A, 最优值 Z_A ; 与之相应的线性规划问题B, 最优值 Z_B 。
- 步2: 从B问题开始, 若B的最优解符合A的整数条件, 则A的最优解为B的最优解 $Z_A = Z_B$
- 步3: 若B的最优解不符合A的整数条件, 则B的最优解对应的一定是A的最优解的上界 Z^- , 而A的某一个任一可行解的目标函数值将是一个下界 Z^- 。

- 步4: 分枝定界法就是不断将B的可行域分成子区域(称为分枝)并在每个子区域中确定A的上界和下界的方法。逐步减小Z上界和增大下界, 最终得到Z。

例子:

例 2-7 求解问题

$$\max \quad 40x_1 + 90x_2 \quad (2-24)$$

$$\text{s.t.} \quad 9x_1 + 7x_2 \leq 56$$

$$7x_1 + 20x_2 \leq 70 \quad (2-25)$$

$$x_1 \geq 0, x_2 \geq 0 \text{ 且取整数}$$

问题B

问题A

记原问题为A, 去掉整数约束后为B

先求解B, 得到最优解 $x_1=4.81, x_2=1.82, z_0=356$, 不符合整数条件, 那么356就是z的一个上界。在可行域中任取一个整数可行解, 如 $x_1=x_2=0$, 那么0就是一个下界。A的最优值必须大于等于A的任意可行解并且小于B的最优解。




图 2-3 问题 B 的图解分析

$$0 \leq Z^* \leq 356$$

第二, 注意B中任一非整数变量解, $x_1=4.81$, 对B增加两个约束条件 $x_1 \leq 4, x_1 \geq 5$ 分割成两个子问题 B1, B2。




图 2-4 问题 B 的分枝

B₂:

$$\max \quad 40x_1 + 90x_2$$

$$s.t. \quad 9x_1 + 7x_2 \leq 56$$

$$7x_1 + 20x_2 \leq 70$$

$$5 \leq x_1$$

表征B2的关键约束

$$x_2 \geq 0$$

B₁:

$$\max \quad 40x_1 + 90x_2$$

$$s.t. \quad 9x_1 + 7x_2 \leq 56$$

$$7x_1 + 20x_2 \leq 70$$

表征B1的关键约束

$$0 \leq x_1 \leq 4$$


$$x_2 \geq 0$$

将B分枝为B1和B2尽管影响了B的求解，但却不影响问题A的求解，因为被割去的部分（图2-4中界于 $x_1=4$ 和 $x_1=5$ 之间的垂直条状域）是 x_1 取非整数的部分，这称为第一次迭代。**得到的最优解是B1**

($z_1=349$, $x_1=4$, $x_2=2.1$)，**B2 ($z_2=341$, $x_1=5$, $x_2=1.57$)**，未得到全整数解，因为 $z_1 > z_2$ ，将上界改为349。

然后对B1与B2再次分枝，因为 $z_1 > z_2$ ，**分支B1**，对 x_2 进行约束，添加 $x_2 \leq 2$, $x_2 \geq 3$ ，分别变为问题**B3**，**B4**

第二次迭代



B₃:

$$\max \quad 40x_1 + 90x_2$$

$$s.t. \quad 9x_1 + 7x_2 \leq 56$$

$$7x_1 + 20x_2 \leq 70$$

$$0 \leq x_1 \leq 4$$

$$0 \leq x_2 \leq 2$$

B₄:

$$\max \quad 40x_1 + 90x_2$$

$$s.t. \quad 9x_1 + 7x_2 \leq 56$$


$$7x_1 + 20x_2 \leq 70$$

$$0 \leq x_1 \leq 4$$

$$3 \leq x_2$$


求解B₃, $z_3=340$, $x_1=4$, $x_2=2$, **由于B₃符合整数条件**, 因此(4, 2)为A的一个可行解, 而A的最优解应该不小于这个可行解对应的值, 因此**下界更新为340**。再解B₄, $z_4=327$, 已经小于A的下界, 没有分解的必要了, **因此B₄舍弃**。此时只剩下了B₃与B₂, B₁中的上界已经达不到了, 因此上界改为B₂的最优值341, **更新上界**。

第三次迭代



$$340 = Z_3 \leq Z^* \leq Z_2 = 341$$

因为B₁中上界已经不复存在, 分解B₂为B₅, B₆



$$Z^* = Z_3 = 340$$


B₅:

$$\begin{aligned} \max \quad & 40x_1 + 90x_2 \\ \text{s.t.} \quad & 9x_1 + 7x_2 \leq 56 \\ & 7x_1 + 20x_2 \leq 70 \\ & 5 \leq x_1 \\ & 0 \leq x_2 \leq 1 \end{aligned}$$

B₆:

$$\begin{aligned} \max \quad & 40x_1 + 90x_2 \\ \text{s.t.} \quad & 9x_1 + 7x_2 \leq 56 \\ & 7x_1 + 20x_2 \leq 70 \\ & 5 \leq x_1 \\ & 2 \leq x_2 \end{aligned}$$

B5的最优解为 $z_5=308$, $x_1=5.44$, $x_2=1$; B6无可行解。因为 z_5 小于下界, 因此A最优解不在B5, B6中, 可以断定最优解就在B3中, 为 $z_3=340$, 对应的 $x_1=4$, $x_2=2$



上述求解过程是通过反复的分枝 (分解可行域)、定界 (确定的上界 Z 和下界 $\bar{Z}$)、剪枝 (剪除最优解值小于下界的可行域) 而完成的, 并且正是由于该方法大面积剪除无最优整数解的区域, 因此计算效率比穷举法高得多。

要点:

- 分枝: 不断分为多个更小的空间

- 定界：确定每个小空间的上、下限和总的上、下界
- 剪枝：根据每个小空间的上、下限和总的上、下界，删掉那些明显低于总下界和无可行解的小空间。

除了分枝定界方法外，割平面法也是解决整数规划的常用方法

2.2 0-1规划以及解法

如果整数规划问题中的所有决策变量 x_i ($i=1, 2, \dots, n$)仅限于取 0 或 1 两个值，则称此问题为 0-1 整数规划，简称为 0-1 规划，其变量 x_i ($i=1, 2, \dots, n$)称为 0-1 变量，或二进制变量，相应的决策变量取值的约束变为 $x_i=0$ 或 1，等价于 $x_i \geq 0$ 和 $x_i \leq 1$ ，且为整数。如果整数规划问题中的一部分决策变量为 0-1 变量，则称为 0-1 混合整数规划。0-1 规划可以是线性的，也可以是非线性的，0-1 线性规划的一般模型

$$\max (\min) z = \sum_{j=1}^n c_j x_j$$

$$\text{为: } \begin{cases} \sum_{j=1}^n a_{ij} x_j \leq (=, \geq) b_i & (i=1, 2, \dots, m), \\ x_j = 0 \text{ 或 } 1 & (j=1, 2, \dots, n). \end{cases}$$

求解方法

显枚举法（又称为穷举法）是把所有可能的组合情况（共 2^n 种组合）列举出后进行比较，找到所需要的解。这种方法对于变量个数较多时，易产生“组合爆炸”，计算量非常巨大。

隐枚举法是从实际出发，从所有可能的组合取值中利用过滤条件排除一些不可能是最优解的情况，只需考查一部分的组合就可以得到最优解。因此，隐枚举法又称为部分枚举法。

例子：

用隐枚举求解

$$\max \quad z = 3x_1 - 2x_2 + 5x_3$$

$$x_1 + 2x_2 - 3x_3 \leq 2 \quad (1)$$

$$x_1 + 4x_2 + x_3 \leq 4 \quad (2)$$

$$x_1 + x_2 \leq 3 \quad (3)$$

$$4x_2 + x_3 \leq 6 \quad (4)$$

$$x_1, x_2, x_3 = 0, 1 \quad (5)$$

原问题A

解：对于三变量的0-1规划，所有变量组合为

(0, 0, 0), (0, 0, 1), (0, 1, 0), (0, 1, 1),
(1, 0, 0), (1, 0, 1), (1, 1, 0), (1, 1, 1)。

首先，通过试探方法找一个可行解，例如(1,0,0)就是满足所有约束条件的可行解之一，此时 $z(1,0,0)=3$

对于上述极大化0-1规划，其最优值 z^* 当然大于等于这个初始的任意解 $z(1,0,0)$ ，所以有

$$z = 3x_1 - 2x_2 + 5x_3 \geq 3 \quad (6)$$

可以想象，如果以(6)来进一步约束原问题A，则那些 $Z < 3$ 的变量组合就可以直接舍弃了。换句话说，后边只要检查 $z \geq 3$ 的变量组合就能确定最优解——这就是“取0-1变量组合的一部分”的含义。

然后，把(6)称为过滤条件，作为一个新约束条件加入到原问题A：

$$\begin{aligned} \max \quad & z = 3x_1 - 2x_2 + 5x_3 \\ & x_1 + 2x_2 - 3x_3 \leq 2 \quad (1) \\ & x_1 + 4x_2 + x_3 \leq 4 \quad (2) \\ & x_1 + x_2 \leq 3 \quad (3) \\ & 4x_2 + x_3 \leq 6 \quad (4) \\ & 3x_1 - 2x_2 + 5x_3 \geq 3 \quad (6) \\ & x_1, x_2, x_3 = 0, 1 \quad (5) \end{aligned}$$

含过滤条件的问题B
B等价于A

第三，构造0-1规划约束条件检查表

将所有约束条件按(6)(1)(2)(3)(4)顺序排好，对每个解依次代入每个约束条件左侧，求出数值，看是否满足约束条件。如果某一约束条件不满足，同一行以下各约束条件就不再检查，因而减少了运算次数。

整数点组合	约束条件左端计算值 / 右端条件值					满足条件否?	Z值
	(6) ≥ 3	(1) ≤ 2	(2) ≤ 4	(3) ≤ 3	(4) ≤ 6		
(000)	0	⊗	⊗	⊗	⊗	×	
(001)	5	-1	1	0	1	√	5
(010)	-2	⊗	⊗	⊗	⊗	×	
(011)	3	1	5	⊗	⊗	×	
(100)	3	1	1	1	0	√	3
(101)	8	0	2	1	1	√	8
(110)	1	⊗	⊗	⊗	⊗	×	
(111)	6	2	6	⊗	⊗	×	

取z值最大的做最优值，最优解为(101)

因为 $6 > 3$ ，所以继续(1)的计算

条件(6)就不满足，后边条件不必再检查

因为 $6 > 4$ 所以不满足条件，打叉，后边的条件(3)(4)不必再计算

从表中可以看出，所有打×的方格，都是没有去计算的组合点，本例只进行了24次运算。而如果采用穷取法，3个变量、4个约束条件，共需要32次运算。本例的最优解是 $z(101)=8$

有两点可以改进，进一步降低计算量：

- 在计算过程中，随时观察表中z值那一列，若遇到z值已超过(6)的右边值(本例为3)，应及时改变条件(6)，使右边成为迄今最大者，然后继续。
例如上表中，计算(001)时得到了z值为5，此时应及时将(6)的右端的3改为5，如果这样做了，则后面的(011)和(100)都不必计算了，进一步降低了计算量。
- 一般常重新排列 x_i 的顺序，使目标函数中 x_i 的系数是只增不减的，这样最优值容易较早发现。

3 非线性规划

定义：如果目标函数或约束条件方程中存在任何非线性因子，则问题为非线性规划。

特点：

1. 目标函数或约束条件方程中存在任何非线性因子，或全部为非线性函数；
2. 没有统一的、通用的解法（这不同于线性规划，它有单纯形法作为通用解法），目前各种解法都有自己的适用范围
3. 非常难以采用解析解法，更多采用数值解法；
4. 非线性规划的最优解不像线性规划那样在边界点达到，而是有可能在可行域中任一点达到；
5. 非线性规划存在局部极值点和全局极值点之分，这一点也与线性规划不同。

标准形式：

模型一：

$$\begin{aligned} \min \quad & f(x) \\ h_i(x) = 0 \quad & i=1, 2 \dots m \quad m \text{个等式约束方程} \\ g_j(x) \geq 0 \quad & j=1, 2 \dots l \quad l \text{个不等式约束方程} \\ x \in R^n \end{aligned}$$

若有另外形式，可转化为以上形式，例：

$$\begin{aligned} \max \quad & f(x) \Rightarrow \min \quad -f(x) \\ g_j(x) \leq 0 \quad & \Rightarrow \quad -g_j(x) \geq 0 \end{aligned}$$

模型二（即没有等式条件，或者把等式条件拆成两个相夹的不等式条件）：

$$\begin{aligned} \min \quad & f(x) \\ g_i(x) \geq 0 \quad & i=1, 2 \dots n \quad n \text{个不等式约束方程} \\ x \in R^n \end{aligned}$$

若没有约束条件，称为无约束极值问题。否则称为约束极值问题。

模型I与模型II的转换：


主要是把等式约束化为不等式约束：

$$h_i(x) = 0 \Rightarrow \begin{cases} h_i(x) \geq 0 \\ h_i(x) \leq 0 \end{cases} \Rightarrow \begin{cases} -h_i(x) \geq 0 \end{cases} \Rightarrow g_i(x) \geq 0$$

解的性态：

线性规划中，当目标函数取定值时，其等值几何图形为直线或平面

非线性规划中，等值线为规则的或不规则的曲线、曲面，类似于地图中的等高线。



3.1 一些定义与定理

定义一：局部极值点（和普通极值点定义一样）：

设 $f(x)$ 为定义在 R^n 中某域 K 上的 n 元实函数，其中 $x = [x_1 \ x_2 \ \cdots \ x_n]^T$ 。

对于 $x^* \in K$ ，如果存在某个 $\varepsilon > 0$ ，使所有与 x^* 距离小于 ε 的 $x \in K$ （即 $x \in K$ 且 $\|x - x^*\| < \varepsilon$ ），均满足不等式 $f(x) \geq f(x^*)$ ，

则称 x^* 为 $f(x)$ 在 K 上的局部极小点， $f(x^*)$ 为局部极小值。

若 $x \neq x^*$ 且 $f(x) > f(x^*)$ ，则 x^* 为严格局部极小点， $f(x^*)$ 为严格局部极小值。

定义二：全局极值点（就是最小点）：

若 $x^* \in K$ 且对所有 $x \in K$ ，都有 $f(x) \geq f(x^*)$ ，则称 x^* 为 $f(x)$ 在 K 上的全局极小点， $f(x^*)$ 为全局极小值。

若 $x \neq x^*$ 且 $f(x) > f(x^*)$ ，则 x^* 为严格全局极小点， $f(x^*)$ 为严格全局极小值。

- 局部极值点和全局极值点在定义上的主要区别是点的比较范围 是 x^* 附近的一个小邻域，还是整个 K 域。
- 局部极小点可能同时是全局极小点，全局极小点同时一定是局部极小点。

定义三：函数的梯度：

设 $x \in K \subset R^n$ ， $f(x)$ 在 K 上有一阶连续偏导数，则

$$\nabla f(x) \triangleq \left[\frac{\partial f(x)}{\partial x_1} \quad \frac{\partial f(x)}{\partial x_2} \quad \cdots \quad \frac{\partial f(x)}{\partial x_n} \right]^T$$

称函数 $f(x)$ 在 x 处的梯度。

梯度几何意义： $\nabla f(x)$ 是 $f(x)$ 在 x 处增加或减少的速度，也是 $f(x)$ 的图形在 x 的陡峭程度

定义四：平稳点：梯度为0的点。若 $\nabla f(x) = 0$ ，则称 x 是 $f(x)$ 的平稳点。

定义五：海赛Hesse矩阵：

若 $f(x)$ 在 K 上有二阶连续偏导数，则


$$H(x) \triangleq \begin{bmatrix} \frac{\partial^2 f(x)}{\partial x_1^2} & \frac{\partial^2 f(x)}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f(x)}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f(x)}{\partial x_2 \partial x_1} & \frac{\partial^2 f(x)}{\partial x_2^2} & \cdots & \frac{\partial^2 f(x)}{\partial x_2 \partial x_n} \\ \cdots & \cdots & \cdots & \cdots \\ \frac{\partial^2 f(x)}{\partial x_n \partial x_1} & \frac{\partial^2 f(x)}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f(x)}{\partial x_n^2} \end{bmatrix}$$

称函数 $f(x)$ 在 x 处的Hesse矩阵。

定理一：极值点必要条件：

若 $f(x)$ 在其存在一阶连续偏导数的区域内达到局部极值点，则该极值点必为平稳点

- 定理一为必要条件，反之不一定成立：平稳点不一定是极值点，例如鞍点（跟函数那个鞍点一样）
- $f(x)$ 在其不满足一阶连续偏导数的区域内的极值点，不一定满足定理一



定义六：矩阵的正定性、负定性、不定性

对于对称矩阵 A ，若对任意向量 $X \neq 0$ ，二次型总为正，即 $X^T A X > 0$ ，则称该二次型为正定二次型， A 为正定矩阵

若 $X^T A X \geq 0$ 半正定

若 $X^T A X < 0$ 负定

若 $X^T A X \leq 0$ 半负定

若既非正定，又非负定，则为不定。

定理二：局部极值点判断的充分条件：

若 $f(x)$ 在 K 上具有二阶连续偏导数，并且满足：

- 1) $x^* \in K$ 是平稳点，即 $\nabla f(x^*)=0$
 - 2) $H(x^*)$ 是正定阵(Hesse阵)
- 则 $x^* \in K$ 是 $f(x)$ 的严格局部极小点。

其实就是一阶导是0，二阶导不为0；二阶导正为极小值。

3.2 求解非线性规划的数值方法——下降迭代算法

求解非线性规划一般有两种方法：

- 解析法：必要条件+充分条件
- 数值法：迭代法

迭代法的思想：

初始估计 $X^{(0)}$ $\xrightarrow{\text{按某种算法}}$ 比 $X^{(0)}$ 更好的 $X^{(1)}$ $\xrightarrow{\text{按算法}}$ $X^{(2)} \dots X^{(n)}$

——→ 得到解序列 $\{X^{(0)}, X^{(1)}, \dots, X^{(n)} \dots\}$

若解序列收敛于 X^* ，即

$$\lim_{k \rightarrow \infty} \|X^{(k)} - X^*\| = 0$$

则称 $\{X^{(0)}, X^{(1)}, \dots, X^{(n)} \dots\}$ 收敛于 X^* 。

结束条件：

- 若算法优秀且收敛的极限值确为最优解，则能通过迭代找到最优解。
- 若迭代步数有限，只能找到近似解，当满足所要求精度时，即停止迭代

常用的几种结束条件

1) 两次迭代值的绝对误差

$$\|X^{(k+1)} - X^{(k)}\| < \varepsilon_1$$

$$|f(X^{(k+1)}) - f(X^{(k)})| < \varepsilon_2$$

2) 两次迭代值的相对误差

$$\frac{\|X^{(k+1)} - X^{(k)}\|}{\|X^{(k)}\|} < \varepsilon_1$$

$$\frac{|f(X^{(k+1)}) - f(X^{(k)})|}{|f(X^{(k)})|} < \varepsilon_2$$

3) 梯度条件

$$\|\nabla f(X^{(k)})\| < \varepsilon$$

下降迭代算法：若某算法产生的解序列使其目标函数值的序列逐渐减小，称这个算法叫下降迭代算法

步骤：

1. 选择某一初始点 $X^{(0)}$ ，令 $k=0$
2. 确定能使 $f(X)$ 下降的搜索方向 $P^{(k)}$

3. 从 $X^{(k)}$ 出发, 沿方向 $P^{(k)}$ 确定迭代步长 λ_k
4. 确定产生下一个迭代点 $X^{(k+1)} = X^{(k)} + \lambda_k P^{(k)}$
5. 检查新点是否为极小点, 或近似极小点, 或满足规定的停止条件; 如果是停止, 否则继续迭代

其中至关重要是: 选取搜索方向 $P^{(k)}$, 确定迭代步长 λ_k

确定迭代步长

1) 一维搜索方法:

一般, 确定步长有三种方法:

- (1) 恒定步长: 步长每次不变, 计算简单, 但效果较差。
- (2) 变步长: 每次人工调整步长, 效果较好, 但实施麻烦, 且值具备较多的经验。
- (3) 最速下降步长: 使得沿搜索方向使目标函数值下降最多、最快, 即沿射线 $X = X^{(k)} + \lambda P^{(k)}$ 求目标函数 $f(X)$ 的极小。

$$\lambda_k : \min f(X^{(k)} + \lambda P^{(k)})$$

由于这种方法是求以 λ 为变量的一元函数 $f(X^{(k)} + \lambda P^{(k)})$ 的极小点 λ_k , 故称为一维搜索, 这样确定的步长为最佳步长。

2) 黄金分割法

2 黄金分割法(0.618 法)

作为一种计算更简便的方法, 黄金分割法在区间缩短效率上近似斐波拉契法。

$$x'_k = a_{k-1} + 0.382[b_{k-1} - a_{k-1}]$$

$$x''_k = a_{k-1} + 0.618[b_{k-1} - a_{k-1}]$$



3.3 无约束非线性规划问题的解

无约束非线性规划问题是: $\min f(X)$

3.3.1 梯度法 (最速下降法)

一般迭代公式为 $X^{(k+1)} = X^{(k)} + \lambda_k P^{(k)}$

$X^{(k)}$ ——第 k 步迭代结果。

$X^{(k+1)}$ ——将要进行的第 $k+1$ 步迭代点。

λ_k ——第 k 步已迭代完成的情况下，下一步的迭代步长。

$P^{(k)}$ ——第 k 步已迭代完成的情况下，下一步的搜索方向。

迭代目标是每次迭代目标函数值都下降

分析：

1) 泰勒展开

① 为此目标，考察 $f(X)$ 在 $X^{(k)}$ 点的泰勒系数(即在 $X^{(k)}$ 对 $f(X)$ 展开)。

$$f(X^{(k+1)}) = f(X^{(k)} + \lambda_k P^{(k)}) \quad (\text{由一般迭代公式})$$

$$= f(X^{(k)}) + \lambda_k \nabla f^T(X^{(k)}) P^{(k)} + o(\lambda_k)$$

$\therefore$ 只要满足上式中间一项 $\lambda_k \nabla f^T(X^{(k)}) P^{(k)} < 0$ ，目标函数就是

下降的，即 $f(X^{(k+1)}) < f(X^{(k)})$ 。

2) P_k 取负梯度方向

进一步，如果希望 $f(X^{(k+1)})$ 在 $f(X^{(k)})$ 的基础上下降的最多，须求合适的 $P^{(k)}$ ，

使泰勒展开式的中间一项 $\lambda_k \nabla f^T(X^{(k)}) P^{(k)}$ **取最大负值**(此时假设 λ_k 已选定)，

为此：

$$\because \lambda_k > 0 \quad \therefore \lambda_k \nabla f^T(X^{(k)}) P^{(k)} < 0 \Rightarrow \nabla f^T(X^{(k)}) P^{(k)} < 0$$

对于 $\nabla f^T(X^{(k)}) P^{(k)} < 0$ 来说， $\nabla f^T(X^{(k)})$ 和 $P^{(k)}$ 是两个矢量(且前者已确定)。

。

由几何学原理知道，**当两个矢量大小相同，方向相反，其点积取最大负值。**

$$\therefore \text{取 } P^{(k)} = -\nabla f^T(X^{(k)})$$

$$\therefore \nabla f^T(X^{(k)}) P^{(k)} = -\nabla f^T(X^{(k)}) \cdot \nabla f^T(X^{(k)}) = -\|\nabla f^T(X^{(k)})\|^2 < 0$$

即为负值，又数值最小。

$\therefore$ 当取 $P^{(k)} = -\nabla f^T(X^{(k)})$ 时， $f(X^{(k+1)})$ 比 $f(X^{(k)})$ 下降的最多。

——称为负梯度方向。

3) 一维搜索求步长

负梯度搜索方向+一维搜索步长=最速下降法

迭代过程：

Step1: 给定初始迭代点 $X^{(0)}$ 及容许精度 $\varepsilon > 0$ 。

若 $\|\nabla f^T(X^{(0)})\|^2 \leq \varepsilon$ ，则 $X^{(0)}$ 即为近似最优解，停止迭代。

Step2: 若 $\|\nabla f^T(X^{(0)})\|^2 > \varepsilon$ ，求步长 λ_0 ，并计算 $X^{(1)} = X^{(0)} - \lambda_0 \nabla f(X^{(0)})$ 。

Step3: 当迭代到第 k 步后，

若 $\|\nabla f^T(X^{(k)})\|^2 < \varepsilon$ ，则 $X^{(k)}$ 即为近似最优解。

否则，则确定下一个迭代点 $X^{(k+1)}$ 为

$$X^{(k+1)} = X^{(k)} - \lambda_k \nabla f(X^{(k)})。$$

并通过黄金分割法求最优的 λ_k 。

3.3.2 共轭梯度法

定义九：正交与共轭

①若 $X \in R^n$ ， $Y \in R^n$ ，当 $X^T Y = 0$ 时，称 X 与 Y 正交。

②若 A 为 $n \times n$ 对称正定阵，当 $X^T A Y = 0$ 时，称 X 和 Y 关于 A 共轭，或 X 和 Y 为 A 共轭。

当 A 为单位阵时，即为 X 和 Y 正交，所以正交是共轭的一种特殊情况。

③设 A 为 $n \times n$ 对称正定阵，若非零向量组 $P^{(1)}, P^{(2)}, \dots, P^{(n)} \in R^n$ ，关于 A 两两共轭，即：

$$(P^{(i)})^T A (P^{(j)}) = 0, \quad i \neq j, \quad i, j = 1, 2, \dots, n。$$

则称向量组为 A 共轭。

定理七：关于 A 共轭的向量组线性无关

定义十：正定二次函数极小问题

无约束极值问题的一个特殊情况是

$$\min f(X) = \frac{1}{2} X^T A X + B^T X + C。$$

其中： A 为 $n \times n$ 对称正定阵， B 为系数向量， C 为常数。

——称为正定二次函数极小问题。

对于正定二次函数极小问题

定理八：

设向量 $P^{(i)}$, $i = 0, 1, 2, \dots, n-1$ 为 A 共轭, 则从任一点 $X^{(0)}$ 出发, 相继以 $P^{(0)}, P^{(1)}, \dots, P^{(n-1)}$ 为搜索方向的迭代算法。

$$\begin{cases} \min_{\lambda} f(X^{(k)} + \lambda P^{(k)}) = f(X^{(k)} + \lambda_k P^{(k)}) \\ X^{(k+1)} = X^{(k)} + \lambda_k P^{(k)} \end{cases}$$

经 n 次迭代后就能收敛于正定二次函数极小问题的最优解。

——称为共轭方向法。

即向每个线性无关的方向都下降了一遍

但是:

一般来说, 共轭方向法仅具有理论分析意义, 对于实际的正定二次函数极小问题求解, 共轭方向法至少有二方面问题没有解决:

① A 共轭的搜索方向向量组理论上为 $P^{(0)}, P^{(1)}, \dots, P^{(n-1)}$, 但实用时如何构造这 n 个向量, 它们具有什么形式, 没有说明。

② 尽管在理论上只需 n 次迭代就能命中目标, 但实际的运算误差的存在, 使问题的解具有不定性。

为此, 发展了共轭方向法的一种具体算法——共轭梯度法

其主要特点是: 基于梯度, 构造了一组可实现的共轭方向, 使算法具有可操作性。

共轭梯度法是一种构造性方法。

比如可以首次迭代的方向 P_0 选当前点负梯度, 第二个方向 P_1 由共轭 P_0 与 P_1 赋值求得, 第三个方向由 P_2 与 P_0 共轭、 P_2 与 P_1 共轭求得, 以此类推直到第 n 个, 即构造最大线性无关组, 每次迭代都由共轭向量组条件新构造下一个方向。

共轭梯度法

对于更广泛的一般无约束非线性规划

$$\min f(X)$$

可以通过在当前迭代点附近足够小的邻域内进行泰勒级数近似的方式, 将一般非线性函数展开成二次函数, 进而采用具有一定迭代精度的共轭梯度法。

$$f(X^{(k+1)}) = f(X^{(k)} + \lambda P^{(k)})$$

$$\approx f(X^{(k)}) + \lambda f^T(X^{(k)})P^{(0)} + \frac{1}{2} \lambda^2 (P^{(k)})^T H(X^{(k)}) P^{(k)}$$

“ $\approx$ ”右边是二次函数。

一般性问题泰勒展开, 截止到二次函数项可以变为正定二次函数

3.3.3 变尺度法

用二阶导数信息确定搜索方向

一种可能是, 采用 $P^{(k)} = -H(X^{(k)})^{-1} \nabla f(X^{(k)})$ 作为搜索方向,

$$\text{即} \begin{cases} X^{(k+1)} = X^{(k)} + \lambda_k P^{(k)} \\ P^{(k)} = -H(X^{(k)})^{-1} \nabla f(X^{(k)}) \\ \lambda_k : \min_{\lambda} f(X^{(k)} + \lambda P^{(k)}) \end{cases}$$

称为广义牛顿法。

$P^{(k)} = -H(X^{(k)})^{-1} \nabla f(X^{(k)})$ 称为 $f(X)$ 在 $X^{(k)}$ 的 **牛顿方向**。

广义牛顿法是一个相当优秀的算法,但在应用时求 Hesse 矩阵的逆很麻烦。为了不计算 Hesse 矩阵(从而不必计算 Hesse 逆), 通过构造一个近似于 Hesse 矩阵的逆矩阵来满足迭代要求。称为变尺度法

构造近似于 $H(X^{(k)})^{-1}$ 的近似矩阵 $H^{(k)}$, 有如下要求:

1. 每一次迭代, 目标函数下降
2. 每一步都能用现有信息确定下一步搜索方向
3. 这些近似矩阵最终收敛于解点处的 Hesse 矩阵的逆

3.4 有约束非线性规划问题 (约束极值问题)

约束极值问题的一般形式为

$$\begin{aligned} \min \quad & f(x) \\ & h_i(x) = 0, \quad i = 1, 2, \dots, m \\ & g_j(x) \geq 0, \quad j = 1, 2, \dots, l \end{aligned}$$

或

$$\begin{aligned} \min \quad & f(x) \\ & g_j(x) \geq 0, \quad j = 1, 2, \dots, l \end{aligned}$$

$$\because \quad h_i(x) = 0 \Leftrightarrow \begin{cases} h_i(x) \geq 0 \\ h_i(x) \leq 0 \end{cases}$$

$\therefore$ 统一采用后一形式

若用集合形式, 则为

$$\begin{aligned} \min \quad & f(x) \quad x \in K \subset R^n \\ & K = \{x \mid g_j(x) \geq 0, \quad j = 1, 2, \dots, l\} \end{aligned}$$

求解要注意以下两点:

1. 目标函数每次迭代都要有所下降
2. 解要在可行域中

三种主要方法:

1. 迭代点严格限制在可行域中
2. 约束极值问题划为无约束问题
3. 复杂约束极值问题化为简单约束问题

3.4.1 库恩塔克条件

假设 x^* 是一个标准非线性规划问题的局部极小点，目标函数和各个约束函数都有一阶连续偏导数，而且在 x^* 处所有起作用的约束的梯度线性无关，则有

设 x^* 是非线性规划

$$\begin{aligned} \min \quad & f(x) \\ & g_j(x) \geq 0, \quad j=1, 2, \dots, l \end{aligned}$$

的局部极小点， $f(x)$ 和 $g_j(x)$, $j=1, 2, \dots, l$ 在点 x^* 有一阶连续偏导数，而且在 x^* 处

所有起作用约束的梯度线性无关，则存在数 $\mu_1^*, \mu_2^*, \dots, \mu_l^*$ ，使

$$\begin{cases} \nabla f(x^*) - \sum_{j=1}^l \mu_j^* \nabla g_j(x^*) = 0 \\ \mu_j^* g_j(x^*) = 0 \quad j=1, 2, \dots, l \\ \mu_j^* \geq 0 \end{cases}$$

即KT条件，满足条件的点为KT点，新定义的数为拉格朗日乘子

四点说明：

1. KT条件是必要条件，只要 x^* 是极值点，且起作用的梯度线性无关，那么条件成立；（极值点 $\rightarrow$ KT；KT not $\rightarrow$ 极值点）
2. 满足KT的点不一定是最优点
3. 对于凸规划，KT条件是充要条件
4. 得到的KT点应该代入到约束条件中验证是否满足

例子：

例：用K-T条件求解非线性规划

$$\begin{aligned} \max \quad & f(x) = (x-4)^2 \\ & 1 \leq x \leq 6 \end{aligned}$$

解：变为标准形式 $\min \quad \tilde{f}(x) = -(x-4)^2$ $\nabla \tilde{f}(x) = -2(x-4)$

$$g_1(x) = x-1 \geq 0 \quad \text{相应梯度} \quad \nabla g_1(x) = 1$$

$$g_2(x) = 6-x \geq 0 \quad \nabla g_2(x) = -1$$

设K-T点为 x^* ，对两个约束条件引入拉格朗日乘子 μ_1^*, μ_2^* ，得到K-T条件：

$$-2(x^*-4) - \mu_1^* + \mu_2^* = 0$$

$$\mu_1^* (x^*-1) = 0$$

$$\mu_2^* (6-x^*) = 0$$

$$\mu_1^* \geq 0, \quad \mu_2^* \geq 0$$

解以上方程组，得到：

$$(1) \mu_1^* > 0, \mu_2^* > 0, \text{无解}$$

$$(2) \mu_1^* > 0, \mu_2^* = 0, x^* = 1, f(x^*) = 9$$

$$(3) \mu_1^* = 0, \mu_2^* = 0, x^* = 4, f(x^*) = 0$$

$$(4) \mu_1^* = 0, \mu_2^* > 0, x^* = 6, f(x^*) = 4$$

∴

∴ 三个 K-T 点 $x^* = 1, x^* = 4, x^* = 6$ ，经验证 $1 \leq x \leq 6$ ，都在可行域内。

最大点为 $x^* = 1, f(x^*) = 9$

最小点为 $x^* = 4, f(x^*) = 0$

3.4.2 可行方向法

对标准形式有：

考察

$$\begin{aligned} \min & f(x) \\ & g_j(x) \geq 0, \quad j = 1, 2, \dots, l \end{aligned}$$

设 $x^{(k)}$ 是第 k 步可行解，则第 $k+1$ 步可行解

$$x^{(k+1)} = x^{(k)} + \lambda_k D^{(k)} \in K$$

且满足 $f(x^{(k+1)}) < f(x^{(k)})$ ， λ_k —— 迭代步长 $D^{(k)}$ —— 某一可行方向

可行方向法是指：满足精度要求停止迭代，不满足继续沿可行方向迭代的算法。

三个特点：

1. 搜索方向为可行方向
2. 迭代点序列一直在可行域内
3. 目标函数单调下降

Zoutendijk可行方向法

假设 $x^{(k)}$ 点的起作用的约束集非空，为了求其下一步的可行下降方向，可以有以下条件：

$$\begin{cases} \nabla f^T(X^{(k)})D < 0 \\ \nabla g_j(X^{(k)})D > 0 \end{cases} \quad j \in J$$

令 $\eta < 0$ ，则上式可化为更严格条件

$$\begin{cases} \nabla f^T(X^{(k)})D \leq \eta \\ -\nabla g_j(X^{(k)})D \leq \eta \\ \eta < 0 \end{cases} \quad j \in J$$

其中D是方向向量，为了寻求一个最佳的可行方向（目标函数下降最多的可行方向），对

$\nabla f^T(X^{(k)})D \leq \eta$ 和 $\nabla g_j(X^{(k)})D \leq \eta$ ($j \in J$) 沿 η 极小化，

讲选取最佳方向问题转化为对 η 的线性规划问题：找到让 η 最小的D（方向）

$$\begin{aligned} \min_D \quad & \eta \\ \text{s.t.} \quad & \nabla f^T(X^{(k)})D \leq \eta \\ & -\nabla g_j(X^{(k)})D \leq \eta \quad j \in J \\ & -1 \leq d_i \leq 1 \quad i=1,2,\dots,n \end{aligned} \quad \left. \vphantom{\begin{aligned} \min_D \quad & \eta \\ \text{s.t.} \quad & \nabla f^T(X^{(k)})D \leq \eta \\ & -\nabla g_j(X^{(k)})D \leq \eta \quad j \in J \\ & -1 \leq d_i \leq 1 \quad i=1,2,\dots,n \end{aligned}} \right\} \text{关于 } D \text{ 的线性规划}$$

其中 d_i 为 D 的第 i 个分量， $-1 \leq d_i \leq 1 \quad i=1,2,\dots,n$ 用于限制 D 的大小。

在之前的算法中都是直接确定方向：如最速下降法的负梯度，变尺度法的牛顿方向，共轭梯度法的共轭方向。而本算法是用n维线性寻优的方法求取一个最优的搜索方向，理论上更完美。

3.4.3 制约函数法

对于有约束的非线性规划问题，通常用以下三种方法处理约束条件：

1. 将迭代点序列严格控制在可行域内，从而执行的迭代过程实际上为无约束优化过程；如可行方向法
2. 序列无约束优化方法，简称SUMT方法，制约函数法。该方法通过将约束项处理成制约函数项加入到目标函数中形成新的广义目标函数，从而将有约束问题转化为广义目标函数下的无约束问题，再利用无约束优化问题算法求解，拉格朗日乘子法是一个特例。
3. 在序列点附近线性化或者序列二次函数逼近，在迭代点附件泰勒展开，将有约束的非线性规划问题近似为简单的线性规划或者二次规划来实现迭代求解。

对第二种的序列无约束优化方法，常用到的制约函数基本上有两类，一类是罚函数，称为外点法；一类是障碍函数，称为内点法。

制约函数法的本质是将有约束非线性规划转为无约束非线性规划

3.4.3.1 惩罚函数法 (外点法)

$$\min f(x)$$
$$x \in R = \{x \mid g_j(x) \geq 0, \quad j = 1, 2, \dots, l\}$$


称为约束非线性规划的原问题。

若能构造一个关于 $g_i(x)$ 的函数，使得满足：

$$\psi(g_j(x)) = \begin{cases} 0 & x \in R \\ \infty & x \notin R \end{cases}$$

则有可能把约束极值问题化为无约束极值问题。

例如，构造一个具有如下图形的 $\psi(\bullet)$ 函数



则复合函数 $\psi(g_j(x)) \rightarrow \psi(x)$

$$\text{再令 } \Phi(x) = f(x) + \sum_{j=1}^l \psi(g_j(x))$$

则上述原问题的约束非线性规划，可以通过 $\Phi(x)$ 化为无约束非线性规划：

$$\min f(x)$$
$$x \in R = \{x \mid g_j(x) \geq 0, \quad j = 1, 2, \dots, l\} \quad \Rightarrow (\text{等价}) \quad \min \Phi(x)$$

没毛病！

验证等价性：当 x 在 R 中，附加惩罚函数是 0，最小值可求；当 x 在 R 外，惩罚函数为正无穷，始终无最小值。


然而上述脉冲函数基本上无法实现，而且在 x 是否在 R 上的边界不连续，性质也不好，在边界上梯度不好求，因此：

把 $\psi(\bullet)$ 改为可实现性和光滑性更好的函数，如下。

$$\psi(g_j(x)) = [\min(0, g_j(x))]^2 = \begin{cases} 0 & x \in R \\ (g_j(x))^2 & x \notin R \end{cases}$$

。

其中，在 $x \notin R$ 处具有二次函数形式的特点。如图：



再取一个充分大的正数M便可构成一个新的目标函数。

$$\begin{aligned} P(x, M) &= f(x) + M \sum_{j=1}^l \psi(g_j(x)) \\ &= f(x) + M \sum_{j=1}^l [\min(0, g_j(x))]^2 \end{aligned}$$

∴ $\min P(x, M)$ 与原问题等价。

式中， $P(x, M)$ 称为**惩罚函数**，右端的第二项称为**惩罚项**， M 称**惩罚因子**。

1. 若 x 在 R 内，则变成无约束非线性规划问题；
若 x 在 R 外，则 x 离 R 越远，惩罚项越大，促使下一步迭代点拉回 R 内
2. 随着 x 被拉回 R 内，乘法项也急剧减小，为了防止乘法项退化，令惩罚因子 M 每次迭代都变化，按一定规律快速增长，使得惩罚有效
3. 此方法相当于把迭代点外的点拉回 R 内，称为外点法；对内部的点不理睬
4. 初始迭代点可以随意选取

迭代流程

1. 取 $M_1 > 0$ ，允许误差 $\varepsilon > 0$ ，令 $k=1$

$$\min P(x, M_k) = P(x^{(k)}, M_k)$$

2. 求无约束线性规划

$$P(x, M_k) = f(x) + M_k \sum_{j=1}^l [\min(0, g_j(x))]^2$$

3. 若 $g_j(x^{(k)}) \leq -\varepsilon$,

则取 $M_{k+1} > M_k$, 令 $k := k+1$, 并转向第2步。

否则, 停止迭代, 得 $x_{\min} = x^{(k)}$.

3.4.3.2 障碍函数法 (内点法)

如果有把握将初始迭代点定义在可行域R内, 那么可以使用障碍函数法来实现无约束化。

主要思想: 找到一个新函数, 其中含有一个障碍项, 当迭代点靠近边界时, 障碍项迅速增大, 阻止迭代点跑到可行域外边。

像选惩罚函数那样, 令 $\sum_{j=1}^l \frac{1}{g_j(x)}$ 或 $\sum_{j=1}^l \log(g_j(x))$ 作障碍项, γ_k 作障碍因子,

构造新的无约束目标函数

$$\min P(x, \gamma_k)$$

$$P(x, \gamma_k) = f(x) + \gamma_k \sum_{j=1}^l \frac{1}{g_j(x)} \quad \gamma_k > 0$$

或

$$P(x, \gamma_k) = f(x) - \gamma_k \sum_{j=1}^l \log(g_j(x)) \quad \gamma_k > 0$$

这样: 当 $x \rightarrow R$ 边界时, $g_j(x) \rightarrow 0 \quad \therefore P(x, \gamma_k) \rightarrow \infty$

1. 初始点选在R内, 越靠近边界, 障碍值越大;
2. 所有的迭代过程都在R内进行
3. 最优点不会在R边界上精确达到, 若实际最优点确实在R边界上, 则可得到近似最优点和近似最优值
4. 为求解边界上或者边界附近的最优点, 可以调整障碍因子

$\gamma_1 > \gamma_2 > \gamma_3 > \dots > 0$, 在边界附近逐步降低障碍函数的影响。

5. 内点法尤其适用于R外性质复杂或者没有定义的情况

3.4.4 逐次逼近方法

主要思路: 对非线性函数进行泰勒展开, 并且逐次逼近, 将复杂的非线性函数转化为线性函数或者简单非线性函数, 再对其进行求解

3.4.4.1 逐次线性规划SLP

针对

$$\begin{aligned} \min \quad & f(x) \\ & g_j(x) \geq 0, \quad j=1, 2, \dots, l \end{aligned}$$

设 $X^{(k)}$ 是第 k 步迭代点，则在 $X^{(k)}$ 附近作泰勒展开

$$\begin{aligned} f(X) &= f(X^{(k)}) + \nabla f^T(X^{(k)}) (X - X^{(k)}) + o(\|X - X^{(k)}\|) \\ &\approx f(X^{(k)}) + \nabla f^T(X^{(k)}) (X - X^{(k)}) \end{aligned}$$

$$\begin{aligned} g_j(X) &= g_j(X^{(k)}) + \nabla g_j^T(X^{(k)}) (X - X^{(k)}) + o(\|X - X^{(k)}\|) \\ &\approx g_j(X^{(k)}) + \nabla g_j^T(X^{(k)}) (X - X^{(k)}) \end{aligned}$$

代入原非线性规划中：

$$\begin{aligned} \min \quad & f(X^{(k)}) + \nabla f^T(X^{(k)}) (X - X^{(k)}) \\ & g_j(X^{(k)}) + \nabla g_j^T(X^{(k)}) (X - X^{(k)}) \geq 0, \quad j=1, 2, \dots, l \end{aligned}$$

这是关于 X 的线性规划。

求解上述线性规划得到新点，若新点在可行域内，则可将其作为新点；若不在，则应缩小步长，重新求线性规划。

在以上泰勒展开中，线性近似的条件是 X 和 X_k 足够近，所以为使得线性近似的误差不太大，应该满足 $\|X - X_k\| < \delta$ ，下一个迭代点的步长也应该小于 δ 。

算法流程：

1. 设定初始迭代点 X_0 和收敛精度因子 $\varepsilon > 0$ ，令 $k=0$
2. 计算目标函数的梯度和约束函数的梯度
3. 设定步长限制 σ ，解线性规划得到下一个迭代点

$$\min \quad f(X^{(k)}) + \nabla f^T(X^{(k)}) (X - X^{(k)})$$

$$g_j(X^{(k)}) + \nabla g_j^T(X^{(k)}) (X - X^{(k)}) \geq 0, \quad j=1, 2, \dots, l$$

$$\|X - X^{(k)}\| < \sigma^{(k)}$$

4. 检验是否在可行域内，如果不是调整 σ 重新计算；如果是下一步
5. 检验新点 $X(k+1)$ 是否满足收敛精度要求以及满足 $\sigma < \varepsilon$ ，若满足则找到了最优解，若不满足继续迭代。

3.4.4.2 逐次二次规划法

同样的泰勒展开，将原目标函数转化为二次近似

$$\begin{aligned} \min \quad & f(x) \\ & g_j(x) \geq 0, \quad j=1,2,\dots,l \end{aligned}$$

设 $X^{(k)}$ 是第 k 步的迭代点，则在 $X^{(k)}$ 附近作泰勒展开。

$$\begin{aligned} f(X) &= f(X^{(k)}) + \nabla f^T(X^{(k)}) (X - X^{(k)}) + \frac{1}{2} (X - X^{(k)})^T H(X^{(k)}) (X - X^{(k)}) + o(\|X - X^{(k)}\|^2) \\ &\approx f(X^{(k)}) + \nabla f^T(X^{(k)}) (X - X^{(k)}) + \frac{1}{2} (X - X^{(k)})^T H(X^{(k)}) (X - X^{(k)}) \end{aligned}$$

式中， $H(X^{(k)})$ 是在 $X^{(k)}$ 点的 Hesse 矩阵。

$$g_j(X) = g_j(X^{(k)}) + \nabla g_j^T(X^{(k)}) (X - X^{(k)}) + o(\|X - X^{(k)}\|)$$

$$\approx g_j(X^{(k)}) + \nabla g_j^T(X^{(k)}) (X - X^{(k)})$$

$$\min \quad f(X^{(k)}) + \nabla f^T(X^{(k)}) (X - X^{(k)}) + \frac{1}{2} (X - X^{(k)})^T H(X^{(k)}) (X - X^{(k)})$$

$$g_j(X^{(k)}) + \nabla g_j^T(X^{(k)}) (X - X^{(k)}) \geq 0 \quad j=1, 2, \dots, l$$

这是一个典型的二次规划 (QP) 问题。

算法流程同SLP流程类似

4 目标规划

提出目标规划用来解决多目标优化问题

一般的多目标优化问题解决方法有：

- 多个目标函数加权处理，按照是最大值还是最小值问题来判断是否加负号
- 多个目标函数中保留一个主目标函数，其他目标函数处理为不低于或者不高于可接受值的约束条件，从而单一化目标函数
- 目标规划

4.1 中心思想

目标规划在处理多目标决策问题时，并不是直接寻找满足这些目标的最优解，而是通过引入“偏差变量”将目标转化为约束处理，以“各个目标的偏差量尽可能小”为原则构造一个新的目标函数，继而求解基于这个新目标函数的单目标规划问题。

本质上，目标规划在“寻求最大限度地满足所有目标的解”

与线性规划区别：

1. 能处理多个目标函数的最优问题
2. 目标规划可在相互矛盾的约束条件下，找到满意解
3. 目标规划找到的不是绝对的最优解，而是与“人为指定目标相比较”的相对最优解
4. 目标规划对约束条件的处理不是“不分主次”，而是有“轻重缓急”

例子：

例 5.1 轿车生产问题

某汽车制造厂根据市场需求拟生产 A, B, C 三种型号的家用轿车. 具体的相关数据如表 5-1 所示. 生产线每天工作 8h, 问该厂如何安排生产计划可使每月 (按 30 天计) 所获利润最大?

表 5-1 相关数据

据 车型	工时 / (h/辆)	市场需求 / (辆 / 月)	利润 / (万元 / 辆)
A	8	10	2.5
B	10	15	3.5
C	12	9	4

解 如果用 x_i ($i=1, 2, 3$) 分别表示 A, B, C 三种车型的生产数量, 一个月正常生产工时为 240h, 则问题可以归结为下面的数学模型

$$\begin{aligned} \max z &= 2.5x_1 + 3.5x_2 + 4x_3 \\ \text{s.t.} \quad &\begin{cases} x_1 \leq 10, \\ x_2 \leq 15, \\ x_3 \leq 9, \\ 8x_1 + 10x_2 + 12x_3 \leq 240, \\ x_i \geq 0 \text{ 且为整数 } (i=1,2,3). \end{cases} \end{aligned} \quad (5.1)$$

每月总工时限制

这是一个单目标的整数规划模型, 直接求解得最优解为 $x_1^*=2$, $x_2^*=14$, $x_3^*=7$, 最优值为 $z^*=82$. 即每月正常分别生产 A, B, C 型轿车 2 辆, 14 辆, 7 辆, 可以获得最大利润 82 万元.

这是一个单目标函数的整数规划, 但是实际生产过程中会有许多额外因素影响。

注意. 上述的市场需求是根据以往的销售数据预测得到的结果, 但实际中的销售情况未必就是这样, 要充分考虑市场条件的变化和实际生产能力的限制条件等因素, 来调整具体的生产方案。比如可能有下列情况出现:

(1) 根据市场情况, 车型 B 的销售量有下降的趋势, 车型 C 有上升的趋势。故应考虑车型 B 的产量不应大于车型 C 的产量;

(2) 车型 A 的原材料成本增加, 使得利润下降, 应适当降低其产量;

(3) 应尽量充分利用原有的设备台时, 而不要加班生产;

(4) 应尽可能达到或超过原计划利润指标 82 万元。

综合考虑上述的几种情况, 重新调整生产方案, 即是多 (4 个) 目标的决策问题了, 这就是目标规划要解决的一类问题。

4.2 一般概念

4.2.1 单目标的目标规划

由于可能受到各种外界环境因素的影响，实际生成销售的利润可能与预期的82万原有些偏差，这种偏差称为偏差量，其值可正可负，分别用 d^+ 和 d^- 表示，并规定 $d^+, d^- \geq 0$

d^+ 表示超额完成指标值的偏差量，即 $d^+ = \text{实际值} - \text{指标值}$

d^- 表示未完成指标值的偏差量，即 $d^- = \text{指标值} - \text{实际值}$

- 如果超额完成指标: $d^+ > 0$ $d^- = 0$
- 如果未完成指标: $d^+ = 0$ $d^- > 0$
- 如果恰好完成指标: $d^+ = 0$ $d^- = 0$

于是我们可以得到 $d^+ \times d^- = 0$

因此，模型(5.1)中的目标函数

$$\max z = 2.5x_1 + 3.5x_2 + 4x_3$$

就可以等价写为

$$2.5x_1 + 3.5x_2 + 4x_3 + d^- - d^+ = 82$$

若 $Z > \text{目标值} 82$ ，则 $Z - d^+ = 82$ ，相当于在目标函数中增加了一个松弛变量；
若 $Z < \text{目标值} 82$ ，则 $Z + d^- = 82$ ；
于是，通过 d^+ 、 d^- 的加入，包括 $\max$ 在内的约束条件与该等式方程等价起来。

也可将其视为一个约束条件（目标函数转化为约束条件）
——在此称为**目标约束**（是软约束），模型中原来的约束条件称为**系统约束**、或**绝对约束**（是硬约束）。

现在的问题是：如何安排生产才能使得工厂能够获得最大利润的82万元呢？

事实上，根据 d^+ 和 d^- 构造新的目标函数：

$$z = d^- + d^+$$

只要该新目标函数 $z = d^- + d^+$ 有最小值 0，就等价于

$$\max z = 2.5x_1 + 3.5x_2 + 4x_3$$

即“使得工厂能够获得最大利润的82万元”。

因此, 模型 (5.1) 可以等价地写成

$$\begin{aligned} \min z &= d^+ + d^- \\ s.t. \quad &\begin{cases} x_1 \leq 10, \\ x_2 \leq 15, \\ x_3 \leq 9, \\ 8x_1 + 10x_2 + 12x_3 \leq 240, \\ 2.5x_1 + 3.5x_2 + 4x_3 + d^- - d^+ = 82, \\ d^-, d^+ \geq 0, \quad x_i \geq 0 \text{ 且为整数 } (i=1,2,3). \end{cases} \end{aligned} \quad (5.2)$$

增加了一个与原目标函数等价的新约束 (是个软约束)。

这里的模型 (5.2) 是单目标问题的目标规划模型, 此与模型 (5.1) 是完全等价的。

4.2.2 多目标的目标规划

当存在 4 个不同目标时, 适当调整生产计划, 但尽量保证利润不减小。依次考虑上面的四个目标:

(1) 应尽可能达到或超过原计划利润指标 82 万元, 即

$$2.5x_1 + 3.5x_2 + 4x_3 + d_1^- - d_1^+ = 82$$

(2) 车型 B 的产量不应大于车型 C 的产量, 即

$$x_2 - x_3 + d_2^- - d_2^+ = 0;$$

(3) 车型 A 的原材料成本增加, 使得利润下降, 应适当降低其量, 即

$$x_1 + d_3^- - d_3^+ \leq 10;$$

(4) 应尽量充分利用原有的设备台时, 而不要加班生产, 即

$$8x_1 + 10x_2 + 12x_3 + d_4^- - d_4^+ \leq 240$$

以上四个目标一般不可能同时达到, 不妨假设优先等级 (重要程度) 是依次排列的, 在这里用优先因子来区分。

排在第一位的目标赋予优先因子为 p_1 , 第二位的优先因子为 p_2 , 依此类推, 第 k 位的优先因子为 p_k ($k=1, 2, 3, 4$), 并规定 $p_k \gg p_{k+1}$ ($k=1, 2, 3, 4$)。

于是, 该问题的目标规划模型为

$$\begin{aligned} \min z &= p_1 d_1^+ + p_2 d_2^+ + p_3 d_3^+ + p_4 (d_4^- + d_4^+) \\ s.t. \quad &\begin{cases} x_1 \leq 10, x_2 \leq 15, x_3 \leq 9, \\ 2.5x_1 + 3.5x_2 + 4x_3 + d_1^- - d_1^+ = 82, \\ x_2 - x_3 + d_2^- - d_2^+ = 0, \\ x_1 + d_3^- - d_3^+ \leq 10, \\ 8x_1 + 10x_2 + 12x_3 + d_4^- - d_4^+ \leq 240, \\ d_j^-, d_j^+ \geq 0 (j=1,2,3,4), \\ x_i \geq 0 \text{ 且为整数 } (i=1,2,3). \end{cases} \end{aligned} \quad (5.3)$$

利润低于 82 万元的量尽可能小

车型 B 高于车型 C 的产量尽可能小

车型 A 产量的超产量尽可能小

设备台时的利用尽可能充分, 少加班

多模型加优先因子。

4.3 一般模型

一般说来,对于任一个多目标决策问题,多个目标总能有主次之分,即可根据各个目标的主次排出优先等级。

不妨设问题有 L (≥ 1) 个目标,可分为 K ($K \leq L$) 个优先等级。排在第 1 位的目标赋予最高的优先因子 p_1 , 第 2 位的赋予优先因子 p_2 , 依此类推,第 k 位的赋予优先因子 p_k ($k \geq 1$), 且规定 $p_k \gg p_{k+1}$ ($k=1, 2, \dots, K-1$)。

如果要区别相同等级的两个目标,通过加权系数来决定其主次:如同等级目标的偏差量 d_k^- , d_k^+ 赋予加权系数 w_k^- , w_k^+ , 这些都是根据实际问题来确定的。

因此模型为

因此,可以给出多目标决策问题的一般的目标规划模型:

$$\min z = \sum_{k=1}^K p_k \left[\sum_{l=1}^L (w_{kl}^- d_l^- + w_{kl}^+ d_l^+) \right]$$

该命题是多目标规划问题转化为“目标规划”模式后的结果

$$s.t. \begin{cases} \sum_{j=1}^n c_{ij} x_j + d_i^- - d_i^+ = g_i \quad (i=1, 2, \dots, L) \\ \sum_{j=1}^n a_{ij} x_j \leq (\geq, =) b_i \quad (i=1, 2, \dots, m) \\ x_j \geq 0 \quad (j=1, 2, \dots, n) \\ d_i^-, d_i^+ \geq 0 \quad (i=1, 2, \dots, L) \end{cases}$$

目标规划下的、体现多目标的单目标目标函数形式

由各个目标转化的软约束

所有硬约束,是多目标模型中原有的

其中 c_{ij} ($j=1, 2, \dots, n; i=1, 2, \dots, L$) 为各目标的相关参数值;

g_i ($i=1, 2, \dots, L$) 为第 1 个目标的指标值;

a_{ij} , b_i ($j=1, 2, \dots, n; i=1, 2, \dots, m$) 为系统约束的相关系数,均为已知常数。

1. 在由实际问题建立目标规划的数学模型时,对于目标的选择、优先等级和加权系数的确定一般都与决策者的主观性有关,因此,实际中可以采用专家评定法或相应的科学方法来决定;
2. 由于目标约束是软约束,实际中不一定要求绝对满足,因此,所得问题的解不一定是可行解,但是满意解
3. 一般根据各目标的具体要求来确定新的目标函数,一般原则是:

○ 如果要求恰好达到目标值,即要求目标的正负偏差都尽可能地小,则取 $\min z = f(d_k^- + d_k^+)$;

如果要求超过指标值,即要求目标的正偏差不限,而负偏差越小越好,则取 $\min z = f(d_k^-)$;

如果要求不超过指标值,即要求目标的负偏差不限,而正偏差越小越好,则取 $\min z = f(d_k^+)$;

按照以上原则先确定各目标的目标函数,再根据各目标的优先级赋予相应优先因子和加权系数,最后构成目标函数的最小化问题。

4. (4) 在模型 (5.4) 中,如果某个目标(如第 l_0 个)不属于第 k_0 个优先等级,则在模型中相应的加权系数 $w_{k_0, l_0}^-, w_{k_0, l_0}^+$ ($1 \leq k_0 \leq K, 1 \leq l_0 \leq L$) 都为 0。

5 动态规划

动态规划是一种解决问题的思想，而不是一种特殊算法，因此没有固定的数学算法。

动态规划问题的分类：根据多阶段决策过程的时间参量是离散还是连续的变量，过程分为离散决策还是连续决策过程；决策过程的演变是确定性还是随机性的。组合起来有离散确定性、离散随机性、连续确定性、连续随机性四种

5.1 基本概念

5.1.1 多阶段决策过程（序贯决策过程）

把一个问题可看作是前后关联、具有链状结构的多阶段过程，并对其 进行决策 ——多阶段决策过程。



在多阶段决策问题中，各个阶段采取的决策一般与时间有关，故 有“动态”的含义。


但是，一些与时间没有关系的静态规划（如线性规划、非线性规划等）问题，只要人为地引进“时间”因素，也可把它视为多阶段决策问题，用动态规划方法去处理

5.1.2 阶段

把过程恰当地分为若干个相互联系的阶段，以便能按一定的次序去 求解。描述阶段的变量称为阶段变量，常用 k 表示。

5.1.3 状态

状态表示每个阶段开始所处的自然状况或客观条件，它描述了研究问题过程的状况



例 1 中，状态就是某阶段的出发位置。它既是该阶段某支路的起点，又是前一阶段某支路的终点。

通常一个阶段有若干个状态，例1中第一阶段有一个状态，就是点A，第二阶段有两个状态，即点集合{ B 1 , B 2 }，一般第 k 阶段的状态就是第 k 阶段所有始点的集合。

描述过程状态的变量称为状态变量，常用 s 表示第 k 阶段的状态变量

例 1 中第三阶段有四个状态，则状态变量 s_k 可取四个值，即 c_1 、 c_2 、 c_3 、 c_4 。

点集合 $\{c_1, c_2, c_3, c_4\}$ 就称为第三阶段的可达状态集合。记为 $S_3 = \{c_1, c_2, c_3, c_4\}$ 。

第 k 阶段的可达状态集合就记为 S_k 。

状态应有的性质：

- 如果某阶段状态给定后，则在这阶段以后过程的发展不受这阶段以前各段状态的影响。
- 换句话说，**过程的过去历史只能通过当前的状态去影响它未来的发展，当前的状态是以往历史的一个完整总结。**
- 这个性质称为**无后效性（即马尔科夫性）**。
- 不满足无后效性要求的量不能作为动态规划的状态

5.1.4 决策

决策表示当过程处于某一阶段的某个状态时，**可以作出的某种决定（或选择）**，从而确定下一阶段的状态，**这种决定称为决策**（在最优控制中也称为控制）。

描述决策的变量称为**决策变量**，用 $u_k(s_k)$ 表示第 k 阶段当状态处于 s_k 时的决策变量，它是状态变量的函数。

在实际问题中，决策变量的取值往往限制在某一范围之内，此范围称为**允许决策集合**，常用 $D_k(s_k)$ 表示第 k 阶段从状态 s_k 出发的允许决策集合， $u_k(s_k) \in D_k(s_k)$ 。

5.1.5 策略

策略是一个按顺序排列的决策组成的集合。

由过程的第 k 阶段开始到终止状态为止的过程，称为问题的后部子过程(或称为 k 子过程)。

由每段的决策按顺序排列组成的决策函数序列 $\{u_k(s_k), u_{k+1}(s_{k+1}) \cdots \cdots u_n(s_n)\}$ 称为 **k 子过程策略**，简称子策略，记为 $p_{k,n}(s_k)$ 。即

$$p_{k,n}(s_k) = \{u_k(s_k), u_{k+1}(s_{k+1}) \cdots \cdots u_n(s_n)\}$$

当 $k=1$ 时，此决策函数序列称为**全过程的一个策略**，简称策略，记为 $p_{1,n}(s_1)$ 。即。

$$p_{1,n}(s_1) = \{u_1(s_1), u_2(s_2) \cdots \cdots u_n(s_n)\}$$

实际问题中，可供选择的策略有一定的范围，此范围称为**允许策略集合**，用 P 表示。

从允许策略集合中找出达到最优效果的策略称为**最优策略**。

5.1.6 状态转移方程

状态转移方程是确定过程从一个到另一个状态的演变过程。

若给定第 k 阶段状态变量 s_k 的值，如果该段的决策变量 u_k 一经确定，第 $k+1$ 阶段的

状态变量 s_{k+1} 的值也就完全确定，即 s_{k+1} 的值随 s_k 和 u_k 的值变化而变化，这种确定的对应关系，记为

$$s_{k+1} = T_k(s_k, u_k)$$

上式描述了由 k 阶段到 $k+1$ 阶段的**状态转移规律**，称为**状态转移方程**。 T_k 称为**状态转移函数**。

例 1 中，状态转移方程为 $s_{k+1} = u_k(s_k)$ 。

5.1.7 指标函数和最优值函数

用来衡量所实现过程优劣的一种数量指标，称为指标函数。它是定义在全过程和所有后部子过程上确定的数量函数。常用 $V_{k,n}$ 表示，即。

$$V_{k,n} = V_{k,n}(s_k, u_k, s_{k+1}, u_{k+1} \cdots \cdots s_{n+1}), k = 1, 2, \cdots n$$

对于要构成动态规划模型的指标函数，应具有**可分离性**，并**满足递推关系**，即 $V_{k,n}$ 可以表

示为 $s_k, u_k, V_{k+1,n}$ 的函数。记为

$$V_{k,n}(s_k, u_k, s_{k+1}, u_{k+1} \cdots \cdots s_{n+1}) = \psi(s_k, u_k, V_{k+1,n}(s_{k+1}, u_{k+1} \cdots \cdots s_{n+1}))$$

简记为 $V_{k,n} = \psi(s_k, u_k, V_{k+1,n})$

常见的指标函数有加和乘两种：

(1) 过程和它的任一子过程的指标是它所包含的**各阶段的指标的和**。即

$$V_{k,n}(s_k, u_k, \dots, s_{n+1}) = \sum_{j=k}^n v_j(s_j, u_j)$$

这时，

$$V_{k,n}(s_k, u_k, \dots, s_{n+1}) = v_k(s_k, u_k) + V_{k+1,n}(s_{k+1}, u_{k+1}, \dots, s_{n+1})$$

(2) 过程和它的任一子过程的指标是它所包含的**各阶段的指标的乘积**。即

$$V_{k,n}(s_k, u_k, \dots, s_{n+1}) = \prod_{j=k}^n v_j(s_j, u_j)$$

这时，

$$V_{k,n}(s_k, u_k, \dots, s_{n+1}) = v_k(s_k, u_k) V_{k+1,n}(s_{k+1}, u_{k+1}, \dots, s_{n+1})$$

指标函数的最优值，称为**最优值函数**，记为 $f_k(s_k)$ 。

它表示从第 k 阶段的状态 s_k 开始到第 n 阶段的终止状态的过程，**当采取最优策略时所得到的指标函数值**。即

$$f_k(s_k) = \operatorname{opt}_{\{u_k, \dots, u_n\}} V_{k,n}(s_k, u_k, \dots, s_{n+1})$$

其中“opt”可根据题意而取 min 或 max。

在不同的问题中，指标函数的含义是不同的，可能是距离、利润、成本、产品的产量或资源消耗等。

5.2 求解方法

5.2.1 逆序方法

对于像例 1 这样的最短路问题，有一个**重要性质**：

(称为**最优性原理**)


如果由起点 A 经过 P 点和 H 点而到达终点 G 是一条最短路线，则由点 P 出发经过 H 点到达终点 G 的这条子路线，对于从点 P 出发到达终点的所有可能选择的不同路线来说，必定也是最短路线。

根据这一性质：

寻找例 1 最短路线的方法，可以考虑从最后一段开始，用由后向前逐步递推的方法，求出各点到 G 点的最短路线，最后求得由 A 点到 G 点的最短路线。

动态规划中这种从终点逐段向始点方向寻找最短路线的策略称为逆序方法。

对上述最短路径问题的逆序求解过程，其实就是向后遍历，依次确定从 k 阶段所有状态到达最终点的最短路径，然后递推到 k-1 阶段时只需考虑 k-1 向 k 阶段的映射关系，具体映射到 k 阶段哪个状态直接代入之前的最短路径即可。



例1的逆序求解过程和结果：

即，将例 1 从最后一段开始计算，由后向前逐步推移至 A 点。

当 $k=6$ 时，由 F_1 到终点 G 只有一条路线，故 $f_6(F_1)=4$ 。同理， $f_6(F_2)=3$ 。

当 $k=5$ 时，出发点有 E_1, E_2, E_3 三个。若从 E_1 出发，则有两个选择：①至 F_1 ；②至 F_2 则

$$f_5(E_1) = \min \begin{cases} d_5(E_1, F_1) + f_6(F_1) \\ d_5(E_1, F_2) + f_6(F_2) \end{cases} = \min \begin{cases} 3 + 4 \\ 5 + 3 \end{cases} = 7$$

其相应的决策为 $u_5(E_1) = F_1$

这说明，由 E_1 至终点 G 的最短距离为 7，其最短路线是

$$E_1 \rightarrow F_1 \rightarrow G$$

同理，从 E_2 和 E_3 出发，则有

$$f_5(E_2) = \min \begin{cases} d_5(E_2, F_1) + f_6(F_1) \\ d_5(E_2, F_2) + f_6(F_2) \end{cases} = \min \begin{cases} 5 + 4 \\ 2 + 3 \end{cases} = 5$$

其相应的决策为 $u_5(E_2) = F_2$

$$f_5(E_3) = \min \begin{cases} d_5(E_3, F_1) + f_6(F_1) \\ d_5(E_3, F_2) + f_6(F_2) \end{cases} = \min \begin{cases} 6 + 4 \\ 6 + 3 \end{cases} = 9$$

且 $u_5(E_3) = F_2$

类似地,可算得:

当 $k=4$ 时,有

$$\begin{array}{ll} f_4(D_1) = 7 & u_4(D_1) = E_2 \\ f_4(D_2) = 6 & u_4(D_2) = E_2 \\ f_4(D_3) = 8 & u_4(D_3) = E_2 \end{array}$$

当 $k=3$ 时,有

$$\begin{array}{ll} f_3(G) = 13 & u_3(G) = D_1 \\ f_3(C_2) = 10 & u_3(C_2) = D_1 \\ f_3(C_3) = 9 & u_3(C_3) = D_2 \\ f_3(C_4) = 12 & u_3(C_4) = D_3 \end{array}$$

当 $k=2$ 时,有

$$\begin{array}{ll} f_2(B_1) = 13 & u_2(B_1) = G \\ f_2(B_2) = 16 & u_2(B_2) = G \end{array}$$

当 $k=1$ 时,出发点只有一个 A 点,则


$$f_1(A) = \min \left\{ \begin{array}{l} d_1(A, B_1) + f_2(B_1) \\ d_1(A, B_2) + f_2(B_2) \end{array} \right\} = \min \left\{ \begin{array}{l} 5 + 13 \\ 3 + 16 \end{array} \right\} = 18$$

且 $u(A) = B_1$ 。于是得到从起点 A 到终点 G 的最短距离为 18。

为了找出最短路线,再按计算的顺序反推之,可求出最优决策函数序列 $\{u_k\}$,即由 $u(A) = B_1, u(B_1) = G, u(C_2) = D_1, u(D_1) = E_2, u(E_2) = F_2, u(F_2) = G$ 组成一个最优策略。因而,找出相应的最短路线为

$$A \rightarrow B_1 \rightarrow C_2 \rightarrow D_1 \rightarrow E_2 \rightarrow F_2 \rightarrow G$$

求解历程如下图所示



上面的计算过程中表明，在求解的各个阶段，利用了 **k 阶段与 k + 1 阶段** 之间的如下 **递推关系**：

$$\begin{cases} f_k(s) = \min_{u_k \in D_k(s)} \{d_k(s, u_k) + f_{k+1}(u_k)\} & k=6,5,4,3,2,1 \\ f_7(s) = 0 \text{ (或写成 } f_6(s) = d_6(s, G)) \end{cases}$$

由此可以得出

一般情况，**k 阶段与 k + 1 阶段** 的递推关系式

$$f_k(s) = \operatorname{opt}_{u_k \in D_k(s)} \{v_k(s, u_k) + f_{k+1}(u_k)\}$$

$$k = n, n - 1, \dots, 1$$

边界条件为


$$f_{n+1}(s_{n+1}) = 0$$

上述这种递推关系式称为**动态规划逆序方法的基本方程**。

5.2.2 顺序方法

例1中，由于线路网络的两端都是固定的，且线路上的数字是表示两点间的距离，则从A点计算到G点和从G点计算到A点的最短路线是相同的。因而，求解过程也可以由A开始，从前向后展开，只不过此时视G为起点，A为终点。

这种以G为始端、A为终端的从A到G的解法称为顺序方法。



5.3 动态规划基本方程的建立

动态规划基本方程又称**递推方程**

5.3.1 动态规划基本方程

对于逆序方法，设指标函数是取各阶段指标的和的形式，即：

$$V_{k,n} = \sum_{j=k}^n v_j(s_j, u_j)$$

其中 $v_j(s_j, u_j)$ 表示第 j 段的指标。

$V_{k,n}$ 显然满足指标函数的可分离性，所以上式可写成

$$V_{k,n} = v_k(s_k, u_k) + V_{k+1,n}[s_{k+1}, \dots, s_{n+1}]$$

当初始状态给定时，过程的策略就被确定，则指标函数也就确定了。

因此，指标函数是初始状态和策略的函数。可记为 $V_{k,n}[s_k, p_{k,n}(s_k)]$

故上面递推关系又可写成

$$V_{k,n}[s_k, p_{k,n}] = v_k(s_k, u_k) + V_{k+1,n}[s_{k+1}, p_{k+1,n}]$$

其子策略 $p_{k,n}(s_k)$ 可看成是由决策 $u_k(s_k)$ 和 $p_{k+1,n}(s_{k+1})$ 组合而成。即

$$p_{k,n} = \{u_k(s_k), p_{k+1,n}(s_{k+1})\}$$

如果用 $p_{k,n}^*(s_k)$ 表示初始状态为 s_k 的后部子过程所有子策略中的最优子策略，则最优值函数为

$$f_k(s_k) = V_{k,n}[s_k, p_{k,n}^*(s_k)] = \underset{p_{k,n}}{\text{opt}} V_{k,n}[s_k, p_{k,n}(s_k)]$$

而

$$\begin{aligned} \underset{p_{k,n}}{\text{opt}} V_{k,n}(s_k, p_{k,n}) &= \underset{\{u_k, p_{k+1,n}\}}{\text{opt}} \{v_k(s_k, u_k) + V_{k+1,n}(s_{k+1}, p_{k+1,n})\} \\ &= \underset{u_k}{\text{opt}} \{u_k(s_k, u_k) + \underset{p_{k+1,n}}{\text{opt}} V_{k+1,n}\} \end{aligned}$$

但

$$f_{k+1}(s_{k+1}) = \underset{p_{k+1,n}}{\text{opt}} V_{k+1,n}(s_{k+1}, p_{k+1,n})$$

所以

$$f_k(s_k) = \underset{u_k \in D_k(s_k)}{\text{opt}} [v_k(s_k, u_k) + f_{k+1}(s_{k+1})] \quad k = n, n-1, \dots, 1$$

边界条件为 $f_{n+1}(s_{n+1}) = 0$ 。

这就是**动态规划逆序解法的基本方程**。

式中 $s_{k+1} = T_k(s_k, u_k)$ 为**状态转移方程**

动态规划基本方程的求解过程：根据边界条件, 从 $k = n$ 开始, 由后向前逆推, 从而逐步可求得各段的最优决策和相应的最优值, 最后求出 $f_1(s_1)$ 时, 就得到整个问题的最优解

5.3.2 基本方程建立原则

1. 将问题的过程划分成恰当的阶段
2. 正确选择状态变量 s_k , 使其既能描述过程的演变, 又满足无后效性
3. 确定决策变量 u_k 以及每阶段允许决策集合 $D_k(s_k)$
4. 正确写出状态转移方程
5. 正确写出指标函数 V_k 的关系, 应该满足:
 - ①是定义在全过程和所有后部子过程上的数量函数;
 - ②要具有可分离性, 并满足递推关系。即

$$V_{k,n}(s_k, u_k, \dots, s_{n+1}) = \psi_k[s_k, u_k, V_{k+1,n}(s_{k+1}, u_{k+1}, \dots, s_{n+1})]$$

③函数 $\psi_k(s_k, u_k, V_{k+1,n})$ 对于变量 $V_{k+1,n}$ 要严格单调。

一旦建立了动态规划模型, 就可以用逆序或顺序方法进行求解。

6 图论

6.1 图的基本概念

图：由一些点以及一些点之间的连线组成的。一些图中连线的两点无先后次序或重要性差别, 而另一些则必须反映这种差别, 通常带箭头的连线表示这种差别

边、弧：不带箭头的连线称为边, 带箭头的连线称为弧

无向图、有向图：如果一个图 G 是由点和边构成的, 称之为无向图 (图), 记为 $G=(V,E)$, V 是 G 的点集合, E 是 G 的边集合, 一条连接点 v_i 和 $v_j \in V$ 的边记为 $[v_i, v_j]$ 或者 $[v_j, v_i]$ 。如果一个图 D 是由点及弧所构成的, 则称为有向图, 记为 $D=(V,A)$, 式中 V, A 分别表示 D 的点集合和弧集合。一条方向是从 v_i 指向 v_j 的弧记为 (v_i, v_j)

点数、边数、弧数：图 G 或 D 中的点数记为 $p(G)$ 或 $p(D)$, 边 (弧) 数记为 $q(G)$ ($q(D)$)。在不会引起混淆的情况下, 也分别简记为 p, q 。

定义五:

- 若边 $e=[u,v] \in E$, 则称 u, v 是 e 的端点, 也称 u, v 是相邻的。称 e 是点 u (及点 v) 的关联边。
- 若图 G 中, 某个边 e 的两个端点相同, 则称 e 是环
- 若两个点之间有多于一条的边, 称这些边为多重边
- 一个无环, 无多重边的图称为简单图
- 一个无环, 但允许有多重边的图称为多重图。

定义六:

以点 v 为端点的边的个数称为 v 的次, 记为 $d_G(v)$ 或 $d(v)$ 。环在计算时算作两次

次为1 的点为悬挂点, 悬挂点的关联边称为悬挂边, 次为零的点称为孤立点。

次为奇数的点, 称为奇点, 否则称为偶点。

链、圈、初等链、初等圈、简单链、简单圈:

给定一个图 $G=(V, E)$, 一个点、边的交错序列 $(v_1, e_1, v_2, e_2, \dots, v_{k-1}, e_{k-1}, v_k)$, 如果满足 $e_t=[v_t, v_{t+1}] (t=1, 2, \dots, k-1)$, 则称一条联结 v_1 和 v_k 的链, 记为 $(v_1, v_2, \dots, v_i), v_2, v_3, \dots, v_{k-1}$ 为链的中间点。

链 $(v_1, v_2, \dots, v_k)$ 中, 若 $v_1 = v_k$, 则称之为一个圈, 记为 $(v_1, v_2, \dots, v_{k-1}, v_1)$ 。

若链 $(v_1, v_2, \dots, v_k)$ 中, 点 $v_1, v_2, \dots, v_k$ 都是不同的, 则称之为初等链;

若圈 $(v_1, v_2, \dots, v_{k-1}, v_1)$ 中, $v_1, v_2, \dots, v_{k-1}$ 都是不同的, 则称之为初等圈;

若链(圈)中含的边均不相同, 则称之为简单圈。

连通图:

图 G 中, 若任何两个点之间, 至少有一条链, 则称 G 是连通图, 否则称为不连通图。

定义九:

设一个图 $G=(V, E)$, 如果图 $G'=(V', E')$, 使 $V=V'$ 及 E' 是 E 的子集, 则称 G' 是 G 的一个支撑子图。

定义十:

设有向图 $D=(V, A)$, 从 D 中去掉所有弧上的箭头, 就得到一个无向图, 称之为 D 的基础图, 记之为 $G(D)$ 。

定义十一:

给 D 中的一条弧 $a=(u, v)$, 称 u 为 a 的始点, v 为 a 的终点, 称弧 a 是从 u 指向 v 的。

设 $(v_1, a_1, v_2, a_2, \dots, v_{k-1}, a_{k-1}, v_k)$ 是 D 中的一个点弧交错序列, 如果这个序列在基础图 $G(D)$ 中所对应的点边序列是一条链, 则称这个点弧交错序列是 D 的一条链。

(不考虑箭头时是连贯的为链)

路、回路:

如果 $(v_1, a_1, v_2, a_2, \dots, v_{k-1}, a_{k-1}, v_k)$ 是 D 中的一条链, 并且对 $t=1, 2, \dots, k-1$, 均有 $a_t=(v_t, v_{t+1})$, 称之为从 v_1 到 v_k 的一条路。若路的第一个点和最后一点相同, 则称之为回路。

(考虑箭头是历次首尾相连的为路)

6.2 树

定义十三:

一个无圈的连通图称为树（每两个点之间都有连线），性质：

- 设图 $G=(V, E)$ 是一个树, $p(G) \geq 2$, 则 G 中至少有两个悬点(次为1的点)
- 图 $G=(V, E)$ 是一个树的充分必要条件是 G 不含圈, 且恰有 $p-1$ 条边。 $q(G) = p(G) - 1$ 。
- 图 $G=(V, E)$ 是一个树的充分必要条件是 G 是连通图, 并且 $q(G) = p(G) - 1$
- 图 G 是树的充分必要条件是任意两个顶点之间恰有一条链。

推论：

- 从一个树中去掉任意一条边, 则余下的图是不连通的。
- 在树中不相邻的两个点间添上一条边, 则恰好得到一个圈, 如果再从这个圈上任意去掉一条边, 可以得到一个树


定义十四： 设图 $T=(V, E')$ 是图 $G=(V, E)$ 的支撑子图, 如果图 $T=(V, E')$ 是一个树, 则称 T 是 G 的一个支撑树。

图 G 有支撑树的充分必要条件是图 G 是连通的。

如何求一个图的支撑树？


方法一：破圈法

任取一个圈, 从圈中去掉一边, 对余下的图重复这个步骤, 直到不含圈时为止, 即得到一个支撑树。



方法二：避圈法

在图中任取一条边 e_1 , 找一条与 e_1 不构成圈的边 e_2 , 再找一条与 $\{e_1, e_2\}$ 不构成圈的边 e_3 , 一般, 设已有 $\{e_1, e_2, \dots, e_k\}$, 找一条与 $\{e_1, e_2, \dots, e_k\}$ 中的任何一条边不构成圈的边 e_{k+1} 。重复这个过程, 直到不能进行为止。这时, 由所有取出的边所构成的图是一个支撑树, 称这种方法为“避圈法”。



赋权图：

给图 $G=(V, E)$, 对 G 中的每一条边 $[v_i, v_j]$, 相应地有一数 w_{ij} , 则称这样的图 G 为赋权图, w_{ij} 称为边 $[v_i, v_j]$ 上的权。

权的物理含义：距离、时间、费用等

最小支撑树：

如果 $T=(V, E')$ 是 G 的一个支撑树, 称 E' 中所有边的权之和为支撑树 T 的权, 记为 $w(T)$ 。


$$W(T) = \sum_{[v_i, v_j] \in T} w_{ij}$$

如果支撑树 T^* 的权 $W(T^*)$ 是 G 的所有支撑树的权中最小者, 则称 T^* 是 G 的最小支撑树(简称最小树)。即

$$W(T^*) = \min_T W(T)$$


如何求最小支撑树?

例：某工厂内联结六个车间的道路网如图所示。已知每条道路的长, 要求沿道路架设联结六个车间的电话线网, 使电话线的总长最小?




破圈法

任取一个圈, 从圈中去掉一条权最大的边(如果有两条或两条以上的边都是权最大的边, 则任意去掉其中一条)。在余下的图中, 重复这个步骤, 直至得到一个不含圈的图为止, 这时的图便是最小树。



避圈法

开始选一条最小权边, 以后每一步中总从未被选中的边中选一条权最小的边, 并不与已选取的边构成圈(若有两条最小权边, 则任选一条)



6.3 最短路径问题

最短路程问题的数学描述

给定一个赋权有向图, 即给了一个有向图 $D=(V, A)$, 对每个弧 $a=(v_i, v_j)$, 相应地有权 $W(a)=w_{ij}$, 又给定 D 中的两个顶点 v_s, v_t 。设 P 是 D 中从 v_s 到 v_t 的一条路, 定义路 P 的权是 P 中所有弧的权之和, 记为 $W(P)$ 。

最短路问题就是要在所有从 v_s 到 v_t 的路中, 求一条权最小的路, 即求一条从 v_s 到 v_t 的路 P_0 , 使

$$W(P_0)=\min_P W(P)$$

式中对 D 的所有从 v_s 到 v_t 的路 P 取最小, 称 P_0 是从 v_s 到 v_t 的最短路。路 P_0 的权称为从 v_s 到 v_t 的距离, 记为 $d(v_s, v_t)$ 。

显然, $d(v_s, v_t)$ 与 $d(v_t, v_s)$ 不一定相等。

上述距离并非只能指里程, 其物理意义可以是费用、时间等其他含义, 完全视权的物理含义而定。

对于无向图, 最短路问题依然存在 (如推销员旅行问题即为其一个变种), 此时称为最短链问题

6.3.1 求解方法 Dijkstra

6.3.1.1 前提


该方法只适用于权 $W \geq 0$ 的情况

该方法不仅求出了从初始点到终点的最短路, 实际上它求出了从初始点到任何一点的最短路

6.3.1.2 理论

如果 P 是 D 中从 v_s 到 v_j 的最短路, v_i 是 P 中的任一途中点, 那么, 从 v_s 沿 P 到 v_i 的路是从 v_s 到 v_i 的最短路。

事实上, 若这个结论不成立, 设 Q 是从 v_s 到 v_i 的最短路, 令 P' 是从 v_s 沿 Q 到达 v_i , 再从 v_i 沿 P 到达 v_j 的路, 那么, P' 的权就比 P 的权小, 这与 P 是从 v_s 到 v_j 的最短路矛盾。



6.3.1.3 思想

通过在图上各点进行标号来寻求最短路，每个点的标号有两种：

一种是临时标号，用T表示；一种是永久标号，用P表示

T标号表示从始点到该点的最短路的某一上界，根据到该点路线的不同，它可能有变化。P标号表示从始点到该点的最短路权，它的值不再改变

标号过程有步骤：

1. 修改T符号：

给定 V_i 是新产生的P标号点，观察以 V_i 为始点的所有弧段 $V_i \rightarrow V_j$ ，

如果 V_j 是P标号点，则对 V_j 不再进行标号；

如果 V_j 是点T标号点，则进行如下修改

$$T(v_j) = \min[T(v_j), P(v_i) + w_{ij}]$$

其中，方括号内的 $T(V_j)$ 代表 V_j 点旧的T标号值，

w_{ij} 为 $V_i \rightarrow V_j$ 弧段的权值。

2. 产生新的P符号：原则如下：在所有现有的T标号点中将值最小者改为P标号，重复以上步骤，直到终点的T标号点变为P标号点为止。

6.3.1.4 流程

设：用 $P(v_i), T(v_i)$ 分别表示 v_i 点的P标号、T标号，

S_i 表示第 i 步时，具有P标号点的集合。

。

为了在求出从 v_s 到各点的距离（权和）的同时，也求出从 v_s 到各点的最短路，

给每个点 v 定义一个表征轨迹的 λ 值 $\lambda(v)$ ，初值全部为 $\lambda(v) = M$ 。

当算法终止时，如果 $\lambda(v) = m$ ，则表示在从 v_s 到 v 的最短路上， v 的前一个

点是 v_m ；如果 $\lambda(v) = M$ ，则表示 D 中不含从 v_s 到 v 的路； $\lambda(v) = 0$ 表示 $v = v_s$ 。

给定赋权有向图 $D=(V,A)$

1. 起始 $i=0$ （先找起始点）：

令P标号集合 $S_0 = \{v_s\}$ ，P标号点的权值 $P(v_s) = 0$ ，路径标记 $\lambda(v_s) = 0$ ，对每一个

$v \neq v_s$ ，令T标号权值 $T(v) = +\infty$ ， $\lambda(v) = M$ 。令 $k = S_0$ 。

2. 第一步：

如果 $S_i = V$ （全部点的集合），算法终止，这时，对每个 $v \in S_i$ ， $d(v_s, v) = P(v)$ ，

即此时已找到了所需最短路；

否则转入“第二步”。

3. 第二步:

考查每个使 $(v_k, v_j) \in A$ (全部弧的集合) 且 $v_j \notin S_i$ 的点 v_j , 即考察所有以 v_k 为始

点的弧段 $v_k \rightarrow v_j$:

如果 $T(v_j) > P(v_k) + w_{kj}$, 则把 $T(v_j)$ 修改为 $P(v_k) + w_{kj}$, 再把 $\lambda(v_j)$ 修改为 k ;

否则转入第三步;

4. 第三步:

令 $T(v_{j_l}) = \min_{v_j \notin S_i} \{T(v_j)\}$, 在所有现有的T标号中找出值最小的那一个。

如果 $T(v_{j_l}) < +\infty$, 则把 V_{j_l} 的 T 标号变为 P 标号 $P(v_{j_l}) = T(v_{j_l})$,

令 $S_{i+1} = S_i \cup \{v_{j_l}\}, k = j$, 即添加到 S 把 $\underline{i}$ 换成 $\underline{i} + 1$, 转入“第一步”; 否则

终止, 这时对每一个 $v \in S_i, d(v_s, v) = P(v)$, 而对每一个 $v \notin S_i, d(v_s, v) = T(v)$, 即

找不到通路。

确定起始点为 P 点, P 值为 0, λ 值为起始点下标 s ; 其余点标为 T 点, 值为无穷, 其余点的 λ 值为 M ; 此时 $k=s$

从起始点找有弧指向的下个点, 按照 T 被指向点 $> P$ 起始点 + 弧权重 的规则更新被指向点的 T 值, 所有被更新的点的 λ 值改为 k ;

在全部的 T 点中找出最小值, 将此点标为 P , 加入到 S 集合中, 令 k 为新加入点的下标, 从新的点开始找有向弧点再更新一波 T , 再找最小值, 再更新到 S 集合, 再更新 k , 以此类推。

当得到所有点的 P 值 λ 值时, 要得到从某个点到某个点的最短路径, 只需逆向遍历 λ 值即可。